

Unidade II

5 PENSAMENTO

O pensamento em inteligência artificial se refere à capacidade dos sistemas de IA de processar e manipular informações para solucionar problemas, aprender e tomar decisões. Em outras palavras, ele diz respeito à capacidade de as máquinas raciocinarem e agirem de forma semelhante aos seres humanos.

Existem várias abordagens para o pensamento em IA, incluindo a lógica, o aprendizado de máquina, o processamento de linguagem natural e a inteligência artificial simbólica. Cada uma delas tem suas próprias vantagens e desvantagens e é adequada para diferentes tipos de tarefas de IA.

Por exemplo, a lógica é usada para representar conhecimento e inferir conclusões a partir de premissas. O aprendizado de máquina é empregado para treinar sistemas de IA a partir de dados e permitir que eles tomem decisões com base em padrões observados nos dados. O processamento de linguagem natural é utilizado para entender e gerar texto e fala em linguagem natural, enquanto a inteligência artificial simbólica tem a função de representar conhecimento em forma de símbolos e realizar inferências lógicas a partir deles.

O pensamento em IA é um campo em constante evolução e é uma área de pesquisa e desenvolvimento ativa na inteligência artificial. À medida que a tecnologia avança, espera-se que as máquinas sejam capazes de realizar tarefas cada vez mais complexas e se aproximarem cada vez mais do pensamento humano.

5.1 Agentes lógicos

Agentes lógicos são programas de computador que utilizam o raciocínio lógico para tomar decisões e realizar ações em um ambiente. Eles usam representações simbólicas para caracterizar conhecimento e inferir conclusões. Os agentes lógicos são comumente usados em áreas como planejamento, diagnóstico, controle de processos e sistemas especialistas.

Trata-se de algumas das principais abordagens utilizadas na inteligência artificial para representar e raciocinar sobre o conhecimento. Eles são compostos de uma série de componentes, como sensores, atuadores, um modelo de ambiente, uma base de conhecimento e um mecanismo de inferência.

Os sensores permitem que o agente perceba o ambiente e os atuadores possibilitam que ele aja nele. O modelo de ambiente é uma representação formal do mundo em que o agente opera, enquanto a base de conhecimento contém as informações que o agente possui sobre o mundo. O mecanismo de inferência é usado para deduzir novas informações a partir das informações existentes na base de conhecimento.

Os agentes lógicos são capazes de raciocinar de forma dedutiva, indutiva e abdutiva, permitindo que eles tomem decisões com base em diferentes tipos de evidências. Eles também podem ser treinados para aprender com exemplos e melhorar seu desempenho ao longo do tempo.

São usados em uma ampla variedade de aplicações de inteligência artificial, incluindo sistemas especialistas, planejamento automatizado, diagnóstico de falhas, controle de processos e sistemas multiagentes. Eles são particularmente úteis em ambientes em que o conhecimento simbólico é mais importante do que o conhecimento baseado em dados, como em medicina, direito e finanças.



Observação

O conhecimento pode ser definido como o conjunto de informações, habilidades e experiências que uma pessoa ou sistema possui. No contexto da inteligência artificial, ele refere-se aos dados e informações utilizados pelos sistemas de IA para aprender e tomar decisões.

Existem duas principais formas de conhecimento na inteligência artificial: conhecimento simbólico e conhecimento baseado em dados.

O primeiro refere-se a informações que são expressas em termos de símbolos, como palavras, regras e conceitos. Esse tipo de conhecimento é utilizado em sistemas de inteligência artificial baseados em lógica, em que as informações são representadas em forma de proposições, regras e inferências. Os sistemas de inteligência artificial baseados em conhecimento simbólico são comumente utilizados em aplicações como sistemas especialistas e sistemas de recomendação.

Já o segundo diz respeito a informações que são extraídas a partir de dados brutos. Ele é utilizado em sistemas de inteligência artificial baseados em aprendizado de máquina, em que os sistemas são treinados com grandes conjuntos de dados para aprender a reconhecer padrões e realizar tarefas específicas. Os sistemas de inteligência artificial baseados em conhecimento baseado em dados são comumente empregados em aplicações como reconhecimento de fala, processamento de imagens e reconhecimento de padrões.

Agentes baseados em conhecimento

Agentes baseados em conhecimento são programas de computador que utilizam representações simbólicas para caracterizar conhecimento e inferir conclusões a partir dele. Eles são um tipo de agente inteligente que utiliza uma base de conhecimento explícita para resolver problemas em um ambiente.

Esses agentes são capazes de representar o conhecimento de um especialista em uma área específica e usá-lo para realizar tarefas, tomar decisões e realizar ações. Eles são projetados para simular o processo de raciocínio humano, permitindo que os usuários interajam com eles de maneira mais natural.

Os agentes baseados em conhecimento geralmente incluem uma base de conhecimento, um mecanismo de inferência e um conjunto de regras ou heurísticas para guiar o processo de tomada de decisão. Eles também podem ser treinados para aprender com exemplos e melhorar seu desempenho ao longo do tempo.

Eles são frequentemente usados em aplicações em que o conhecimento especializado é crítico, como na medicina, direito, finanças e engenharia. Eles são capazes de lidar com problemas complexos e ambíguos, permitindo que os usuários obtenham respostas mais precisas e confiáveis.

Mundo de Wumpus

O mundo de Wumpus é um problema clássico da inteligência artificial que é frequentemente usado para testar algoritmos de raciocínio baseados em lógica. O problema foi proposto por Stuart Russell e Peter Norvig em seu livro *Artificial intelligence: a modern approach* e consiste em um agente que deve navegar em um labirinto para encontrar um tesouro, evitando um monstro chamado Wumpus.

É representado por uma grade de células (figura 28), cada uma contendo um ou mais elementos, como poços, paredes, Wumpus e o tesouro. O agente deve usar seus sensores para obter informações sobre o ambiente e inferir a localização do tesouro e do Wumpus.

O agente pode se mover de uma célula para outra e realizar ações, como atirar uma flecha para matar o Wumpus ou pegar o tesouro. No entanto, ele deve ser cuidadoso, pois pode cair em um poço ou ser atacado pelo Wumpus se não for precavido.

O problema do mundo de Wumpus é um exemplo clássico de busca em inteligência artificial, em que o objetivo é encontrar uma solução que leve o agente ao tesouro. Existem muitos algoritmos de busca que podem ser usados para resolver esse problema, incluindo a busca em profundidade, busca em largura, busca de custo uniforme e algoritmos heurísticos, como a busca A*.

Trata-se de um problema interessante na inteligência artificial, porque envolve raciocínio lógico, inferência, planejamento e tomada de decisão. Ele também pode ser usado para testar a eficácia de diferentes técnicas de resolução de problemas e algoritmos de busca em ambientes complexos e incertos.

Uma das principais dificuldades do mundo de Wumpus é que ele envolve incerteza e ambiguidade. Por exemplo, o agente pode não saber exatamente onde o Wumpus está localizado ou se há um poço em uma célula específica. Isso torna o problema mais desafiador e requer que o agente use técnicas de inferência e incerteza para tomar decisões.

Uma abordagem comum para sua resolução é a lógica proposicional, que é uma linguagem formal para representar conhecimento e raciocínio. Ela pode ser usada para caracterizar a estrutura do labirinto e as relações entre as células, permitindo que o agente deduza informações sobre o ambiente.

Outra abordagem para resolver o problema é a lógica de predicados, que é uma linguagem formal mais expressiva que possibilita representar conhecimento mais complexo e fazer inferências mais

precisas. Ela pode ser usada para caracterizar o conhecimento do agente sobre o ambiente, como as propriedades do Wumpus e as localizações possíveis do tesouro.

Tal problema é usado para testar algoritmos de raciocínio lógico, planejamento e inferência. Trata-se de uma ferramenta valiosa para aprender os conceitos fundamentais da inteligência artificial.




Figura 28 – Um mundo de Wumpus típico. O agente está no canto inferior esquerdo virado para a direita

Fonte: Russell e Norvig (2013, p. 201).

1,4	2,4	3,4	4,4
1,3	2,3	3,3	4,3
1,2	2,2	3,2	4,2
1,1 A OK	2,1 OK	3,1	4,1

A) = Agente
B = Brisa
R = Brilho, ouro
OK = Quadrado seguro
P = Poço
F = Fedor
V = Visitado
W = Wumpus

1,4	2,4	3,4	4,4
1,3	2,3	3,3	4,3
1,2 OK	2,2 P?	3,2	4,2
1,1 V OK	2,1 A B OK	3,1 P?	4,1

B)

Figura 29 – O primeiro passo dado pelo agente no mundo de Wumpus. A) A situação inicial, depois da percepção [Nada, Nada, Nada, Nada, Nada]. B) Depois de um movimento, com a percepção [Nada, Brisa, Nada, Nada, Nada]

Fonte: Russell e Norvig (2013, p. 202).

1,4	2,4	3,4	4,4
1,3 W!	2,3	3,3	4,3
1,2 A S OK	2,2 OK	3,2	4,2
1,1 V OK	2,1 B V OK	3,1 P!	4,1

A)

A = Agente
B = Brisa
R = Brilho, ouro
Ok = Quadrado seguro
P = Poço
F = Fedor
V = Visitado
W = Wumpus

1,4	2,4 p?	3,4	4,4
1,3 W!	2,3 A S G B	3,3 P?	4,3
1,2 S V OK	2,2 V OK	3,2	4,2
1,1 V OK	2,1 B V OK	3,1 P!	4,1

B)

Figura 30 – Duas fases posteriores no progresso do agente. A) Depois do terceiro movimento, com a percepção [Fedor, Nada, Nada, Nada, Nada]. B) Depois do quinto movimento, com a percepção [Fedor, Brisa, Brilho, Nada, Nada]

Fonte: Russell e Norvig (2013, p. 202).

Lógica

Lógica na inteligência artificial é uma ferramenta fundamental para representar o conhecimento e raciocinar sobre o mundo. Trata-se de uma disciplina que se preocupa com as regras do raciocínio válido e pode ser aplicada de várias maneiras.

Em IA, a lógica é frequentemente usada para representar o conhecimento de um domínio, como as propriedades de objetos, as relações entre objetos e as ações que podem ser realizadas em um ambiente. A representação do conhecimento em lógica permite que um agente de IA possa inferir novos fatos a partir de fatos já conhecidos e tomar decisões com base neles.



Lembrete

Conhecimento do domínio é aquele específico e especializado sobre um determinado campo de interesse, que é adquirido e utilizado para resolver problemas nesse domínio. Ele é essencial na construção de sistemas inteligentes que possam automatizar tarefas ou auxiliar na tomada de decisões em um dado domínio.

A lógica é amplamente utilizada em sistemas especialistas, que são sistemas de IA projetados para imitar a capacidade de um especialista humano em um domínio específico. Esses sistemas são capazes de representar o conhecimento do especialista em um formato lógico e usar técnicas de inferência para deduzir novas informações a partir do conhecimento existente.

Existem várias linguagens formais de lógica usadas em inteligência artificial, como a lógica proposicional, a lógica de predicados e a lógica modal. Cada uma dessas linguagens tem diferentes graus de expressividade e complexidade, permitindo que os agentes de IA representem diversos tipos de conhecimento.

Afora ser usada para representar o conhecimento, a lógica é empregada para construir algoritmos de raciocínio em inteligência artificial, como a resolução de problemas e a tomada de decisão. Esses algoritmos usam a lógica para inferir novas informações a partir de fatos conhecidos e tomar decisões.

Na figura 31, utilizando a lógica, podemos criar os modelos possíveis para representar o mundo de Wumpus.




Figura 31 – Modelos possíveis para representar a presença de poços nos quadrados [1,2], [2,2] e [3,1]. BC corresponde às observações de nada em [1,1] e brisa em [2,1] é mostrada pela linha sólida. A) As linhas pontilhadas mostram modelos de α_1 (nenhum poço em [1,2]). B) as linhas pontilhadas mostram modelos de α_2 (nenhum poço em [2,2])

Fonte: Russell e Norvig (2013, p. 204).

Lógica proposicional

A lógica proposicional é uma linguagem formal utilizada na inteligência artificial para representar o conhecimento e raciocinar sobre o mundo. Ela é um ramo da lógica matemática que lida com proposições, ou seja, declarações que podem ser verdadeiras ou falsas.

Na lógica proposicional, as proposições são representadas por símbolos, como p, q, r, e assim por diante, e são combinadas usando operadores lógicos, como negação (\neg), conjunção (\wedge), disjunção (\vee), implicação (\rightarrow) e equivalência (\leftrightarrow).

Sentença \rightarrow SentençaAtômica | SentençaComplexa
 SentençaAtômica \rightarrow Verdadeiro | Falso | P | Q | R | ...
 SentençaComplexa \rightarrow (Sentença) | [Sentença]
 | \neg Sentença
 | (Sentença \wedge Sentença)
 | (Sentença \vee Sentença)
 | (Sentença \Rightarrow Sentença)
 | (Sentença \Leftrightarrow Sentença)
 Precedência de operadores: $\neg, \wedge, \vee, \Rightarrow, \Leftrightarrow$

Figura 32

Fonte: Russell e Norvig (2013, p. 207).

P	Q	$\neg P$	$P \wedge Q$	$P \vee Q$	$P \Rightarrow Q$	$P \Leftrightarrow Q$
Falso	Falso	Verdadeiro	Falso	Falso	Verdadeiro	Verdadeiro
Falso	Verdadeiro	Verdadeiro	Falso	Verdadeiro	Verdadeiro	Falso
Verdadeiro	Falso	Falso	Falso	Verdadeiro	Falso	Falso
Verdadeiro	Verdadeiro	Falso	Verdadeiro	Verdadeiro	Verdadeiro	Verdadeiro

Figura 33

Fonte: Russell e Norvig (2013, p. 209).

Por exemplo, suponha que um agente de IA está navegando em um labirinto e quer representar a informação de que existem poços em determinadas células. Ele pode usar a lógica proposicional para caracterizar essa informação da seguinte maneira:

- **p1**: existe um poço na célula (1,1).
- **p2**: existe um poço na célula (2,3).
- **p3**: existe um poço na célula (3,2).

Agora, o agente pode usar operadores lógicos para combinar essas proposições e inferir novas informações. Por exemplo, pode utilizar o operador " \neg " (negação) para representar o dado de que uma célula não contém um poço:

- **$\neg p4$** : não há poço na célula (1,2).

O agente também pode usar o operador " \wedge " (conjunção) para combinar proposições e representar informações mais complexas, como:

- **p5:** existem poços nas células (1,1) e (2,3).
- **p6:** existe um poço na célula (1,1) e não há poço na célula (1,2).

A lógica proposicional é uma ferramenta poderosa na inteligência artificial, permitindo que os agentes representem o conhecimento e infiram novas informações com base nesse conhecimento. No entanto, ela tem algumas limitações, como a falta de expressividade para representar conhecimento mais complexo. Nesses casos, outras linguagens formais, como a lógica de predicados, podem ser mais adequadas.

Além disso, é usada em sistemas de inferência, que são aqueles de inteligência artificial que usam o conhecimento para deduzir novas informações. Neles, as proposições são empregadas para representar fatos conhecidos e as regras de inferência são utilizadas para deduzir novas informações a partir desses fatos.

Por exemplo, suponha que um agente de IA está tentando diagnosticar um problema em um sistema de computador. Ele pode usar a lógica proposicional para representar os sintomas do problema da seguinte forma:

- **p1:** o sistema não inicializa.
- **p2:** o monitor não liga.
- **p3:** o sistema emite um som estranho.
- **p4:** o mouse não responde.

O agente também pode usar proposições para representar as possíveis causas do problema:

- **q1:** o cabo de alimentação está desconectado.
- **q2:** a placa de vídeo está com defeito.
- **q3:** o disco rígido falhou.

Usando regras de inferência, como a *modus ponens*, o agente pode inferir novas informações a partir dos fatos e das causas conhecidas. Por exemplo, se ele sabe que o cabo de alimentação está desconectado, pode inferir que o sistema não inicializa:

- **p1:** o sistema não inicializa.
- **q1:** o cabo de alimentação está desconectado.
- **Inferência:** se o cabo de alimentação está desconectado, então o sistema não inicializa ($p1 \wedge q1$).



Observação

O modus ponens é um conceito muito utilizado na lógica. Não devemos confundir com uma lei da lógica, pois trata-se de um mecanismo aceito para a construção de provas dedutivas, que inclui a "regra de definição" e a "regra de substituição".

A lógica proposicional é uma ferramenta útil para representar e inferir conhecimento em sistemas de IA. No entanto, ela tem algumas limitações, como a incapacidade de representar quantificadores, como "todos" e "alguns", bem como de informações sobre objetos individuais, por exemplo, suas propriedades e relações. Nessas situações, outras linguagens formais, como a lógica de predicados, podem ser mais adequadas.

Prova de teoremas proposicionais

A prova de teoremas proposicionais é uma técnica usada na inteligência artificial para determinar se uma afirmação é verdadeira ou falsa, com base em um conjunto de axiomas e regras de inferência. Ela é empregada principalmente em sistemas de lógica proposicional, sendo útil para verificar a consistência do conhecimento representado nesses sistemas.



Lembrete

Um axioma é uma afirmação ou proposição considerada verdadeira, e que não precisa ser demonstrada ou provada. Em outras palavras, trata-se de uma premissa básica ou um pressuposto aceito como verdadeiro, que serve como fundamento para um sistema lógico, teoria ou ciência. Os axiomas são usados para construir argumentos ou provas, e são considerados autoevidentes e indiscutíveis. Eles geralmente são definidos no início de uma teoria ou ciência e usados como base para a construção de outros conceitos e teoremas.

As regras de inferência são um conjunto de regras lógicas que permitem deduzir novas proposições ou conclusões a partir de proposições ou premissas já conhecidas. Elas são usadas em lógica, matemática, ciência da computação e outras áreas para construir argumentos e inferir novas informações a partir de conhecimentos prévios.

Uma prova de teoremas proposicionais começa com um conjunto de axiomas, que são proposições consideradas verdadeiras sem a necessidade de prová-las. A partir deles, o sistema aplica regras de inferência para derivar novas proposições, até chegar à proposição que se deseja provar.

Existem várias técnicas para realizar a prova de teoremas proposicionais, incluindo a prova direta, a prova por contradição e a prova por indução. Em geral, elas envolvem a aplicação cuidadosa das regras de inferência para evitar erros e garantir que a prova seja válida.

A prova de teoremas proposicionais é importante porque permite que os agentes verifiquem se o conhecimento representado em um sistema de lógica proposicional é consistente e livre de contradições. Além disso, a prova de teoremas proposicionais pode ser usada para inferir novas proposições com base em um conjunto de axiomas e regras de inferência, permitindo que os agentes gerem novo conhecimento a partir de outro existente.

No entanto, a prova de teoremas proposicionais pode ser computacionalmente cara e difícil de automatizar em sistemas mais complexos. Por essa razão, outras técnicas de raciocínio, como a inferência baseada em modelos, são frequentemente usadas com a prova de teoremas proposicionais para permitir que os agentes lidem com conhecimento mais complexo.

A prova de teoremas proposicionais também pode ser útil em outras áreas da inteligência artificial, como o planejamento automatizado. Por exemplo, suponha que um agente de IA esteja tentando planejar uma sequência de ações a fim de atingir um objetivo específico. Ele pode usar a prova de teoremas proposicionais para verificar se um conjunto de ações é válido e consistente com seu conhecimento prévio.

Além disso, a prova de teoremas proposicionais é usada em sistemas de verificação formal, empregados para verificar a correção de software e hardware. Nesses sistemas, a prova de teoremas proposicionais é usada para verificar se um sistema cumpre determinadas propriedades de segurança ou de desempenho, garantindo que ele seja seguro e confiável.

Embora a prova de teoremas proposicionais tenha suas limitações, ela é uma ferramenta importante na inteligência artificial e pode ser usada para resolver muitos problemas difíceis e complexos. Com o desenvolvimento contínuo da tecnologia, espera-se que a prova de teoremas proposicionais e outras técnicas de raciocínio sejam cada vez mais eficientes e eficazes na solução de problemas de inteligência artificial.

$(\alpha \wedge \beta) \equiv (\beta \wedge \alpha)$ comutatividade de \wedge
 $(\alpha \vee \beta) \equiv (\beta \vee \alpha)$ comutatividade de \vee
 $((\alpha \wedge \beta) \wedge \gamma) \equiv (\alpha \wedge (\beta \wedge \gamma))$ associatividade de \wedge
 $((\alpha \vee \beta) \vee \gamma) \equiv (\alpha \vee (\beta \vee \gamma))$ associatividade de \vee
 $\neg(\neg\alpha) \equiv \alpha$ eliminação da dupla negação
 $(\alpha \Rightarrow \beta) \equiv (\neg\beta \Rightarrow \neg\alpha)$ contraposição
 $(\alpha \Rightarrow \beta) \equiv (\neg\alpha \vee \beta)$ eliminação da implicação
 $(\alpha \Leftrightarrow \beta) \equiv ((\alpha \Rightarrow \beta) \wedge (\beta \Rightarrow \alpha))$ eliminação da bicondicional
 $\neg(\alpha \wedge \beta) \equiv (\neg\alpha \vee \neg\beta)$ De Morgan
 $\neg(\alpha \vee \beta) \equiv (\neg\alpha \wedge \neg\beta)$ De Morgan
 $(\alpha \wedge (\beta \vee \gamma)) \equiv ((\alpha \wedge \beta) \vee (\alpha \wedge \gamma))$ distribuição de \wedge sobre \vee
 $(\alpha \vee (\beta \wedge \gamma)) \equiv ((\alpha \vee \beta) \wedge (\alpha \vee \gamma))$ distribuição de \vee sobre \wedge

Figura 34

Fonte: Russell e Norvig (2013, p. 212).

Verificação eficiente de modelos proposicionais

A verificação eficiente de modelos proposicionais é uma técnica usada na inteligência artificial para verificar se um modelo de conhecimento proposicional é válido e consistente. Ela é importante porque pode ajudar a identificar erros e contradições no modelo, garantindo que ele seja útil e confiável.

Um modelo proposicional é uma representação formal do conhecimento em que as proposições são expressas como símbolos e as relações entre elas são apresentadas como conectivos lógicos, por exemplo, "e", "ou" e "não". A verificação eficiente de modelos proposicionais envolve o uso de algoritmos para analisar o modelo e determinar se ele satisfaz determinadas propriedades.

Existem vários algoritmos que podem ser usados para verificar eficientemente modelos proposicionais, incluindo a resolução binária, a técnica DPLL e a técnica de diagramas de decisão binária. Eles são capazes de verificar modelos com milhares de variáveis e cláusulas em questão de segundos, tornando a verificação eficiente de modelos proposicionais uma técnica útil e escalável para lidar com problemas de inteligência artificial.

A verificação eficiente de modelos proposicionais é usada em uma ampla gama de aplicações de inteligência artificial, incluindo a verificação formal de software e hardware, o planejamento automatizado, o diagnóstico de falhas e a síntese de controladores. A técnica também é empregada para testar modelos de conhecimento, identificar erros e contradições e gerar novas hipóteses a partir do modelo existente.

Trata-se de uma técnica importante, pois permite que os agentes de IA verifiquem a validade e a consistência de modelos de conhecimento proposicional. Com o avanço contínuo da tecnologia, espera-se que a verificação eficiente de modelos proposicionais e outras técnicas de raciocínio sejam cada vez mais melhores na solução de problemas de inteligência artificial.

Agentes baseados em lógica proposicional

Agentes baseados em lógica proposicional são aqueles de inteligência artificial que utilizam a lógica proposicional para representar seu conhecimento e raciocinar sobre ele. A lógica proposicional é uma forma de lógica que lida com proposições (afirmações verdadeiras ou falsas) e conectores lógicos (como "e", "ou" e "não") que podem ser usados para combinar proposições em fórmulas mais complexas.

Eles geralmente têm um conjunto de proposições que representam seu estado atual e usam regras de inferência baseadas em lógica proposicional para derivar novas proposições a partir das já existentes. Essas regras de inferência podem ser usadas para modelar o comportamento de um agente, permitindo que ele tome decisões e aja de forma autônoma em um ambiente.

Um exemplo de agente baseado em lógica proposicional é o agente do mundo de Wumpus. Nesse jogo, o agente deve navegar por um labirinto escuro, evitando buracos e um monstro chamado Wumpus.

O agente pode usar a lógica proposicional para modelar seu conhecimento sobre o mundo, por exemplo, inferindo a localização do Wumpus a partir de sons que ele ouve, sendo capaz de usar esse conhecimento para decidir qual movimento tomar em seguida.

Os agentes baseados em lógica proposicional são úteis em uma variedade de aplicações nas quais a lógica proposicional é uma forma natural de representação do conhecimento e podem ajudar a resolver problemas complexos de maneira eficiente e eficaz. Existem diversos exemplos de agentes baseados em lógica proposicional na inteligência artificial. Aqui estão alguns deles:

- **Agente de diagnóstico médico:** um agente de diagnóstico médico pode usar a lógica proposicional para representar sintomas e possíveis doenças. Por exemplo, se um paciente tem febre e tosse, o agente pode usar a lógica proposicional para inferir que o indivíduo pode ter uma infecção respiratória. O agente pode então sugerir um conjunto de testes para confirmar ou descartar essa hipótese.
- **Agente de planejamento:** um agente de planejamento pode usar a lógica proposicional para representar metas e restrições. Por exemplo, se um agente de planejamento está planejando uma viagem de avião, ele pode usar a lógica proposicional para representar as restrições de horário de voos e a disponibilidade de assentos. O agente pode então usar essas informações para encontrar a melhor opção de voo que atenda às suas metas.
- **Agente de segurança:** um agente de segurança pode usar a lógica proposicional para representar possíveis violações e medidas de segurança. Por exemplo, quando em um aeroporto, pode usar a lógica proposicional para representar possíveis ameaças, como passageiros que tentam embarcar com objetos perigosos. O agente consegue empregar essa informação para decidir quais medidas de segurança devem ser tomadas para garantir a segurança do aeroporto.
- **Agente de jogos:** um agente de jogos pode usar a lógica proposicional para representar as regras do jogo e a situação atual do jogo. Por exemplo, um agente de xadrez pode usar a lógica proposicional para caracterizar as posições das peças no tabuleiro e as regras de movimento de cada peça. Ele pode então usar essa informação para decidir qual movimento precisa ser feito a seguir.

Esses são apenas alguns exemplos de como os agentes baseados em lógica proposicional podem ser usados na inteligência artificial. Em geral, trata-se de uma ferramenta poderosa para representar o conhecimento de um agente e permitir que ele tome decisões e aja de forma autônoma em um ambiente complexo.

5.2 Lógica de primeira ordem (LPO)

A lógica de primeira ordem (LPO) é uma extensão da lógica proposicional que permite representar e raciocinar sobre quantificadores e variáveis. Na LPO, é possível quantificar sobre objetos e expressar propriedades que são compartilhadas por diferentes objetos.

Ela é usada na inteligência artificial para representar conhecimento mais complexo do que a lógica proposicional permite. Por exemplo, na LPO é possível caracterizar afirmações como "Todos os gatos são animais" e "Existe um cachorro que late". Isso possibilita que os agentes de inteligência artificial representem e manipulem conhecimento mais sofisticado sobre o mundo.

A LPO também é usada em tarefas como o raciocínio dedutivo e a inferência automatizada. Por exemplo, um agente de diagnóstico médico pode usá-la para representar afirmações sobre sintomas, doenças e tratamentos, e usar inferência automatizada a fim de chegar a um diagnóstico.

Representação

A LPO é representada em inteligência artificial através de uma linguagem formal que permite expressar proposições complexas usando símbolos e regras gramaticais. Essa linguagem é chamada de linguagem de primeira ordem ou lógica de predicados.

A linguagem de primeira ordem consiste em símbolos para constantes, funções, predicados e variáveis. Constantes representam objetos específicos, como números ou nomes próprios. Funções caracterizam mapeamentos de objetos em outros objetos. Predicados representam propriedades ou relações que podem ser aplicadas a objetos. Variáveis são usadas para representar objetos não especificados.

Por exemplo, suponha que queremos representar a proposição "Todos os gatos são animais". Conseguimos fazer isso usando a LPO, com um símbolo de predicado "gato(x)" que representa a propriedade de ser um gato e um símbolo de predicado "animal(x)" que caracteriza a propriedade de ser um animal. A proposição pode ser escrita como "para todo x, se gato(x), então animal(x)".

Além disso, na LPO, é possível usar quantificadores para expressar a extensão das variáveis. Existem dois quantificadores na LPO: o quantificador universal, representado por "para todo" (\forall), que indica que a proposição se aplica a todos os valores da variável, e o quantificador existencial, representado por "existe" (\exists), que indica que a proposição é verdadeira para pelo menos um valor da variável.

Assim, por exemplo, a proposição "Existe um cachorro que late" pode ser escrita em LPO como "Existe um x tal que cachorro(x) e late(x)".

A LPO é representada em inteligência artificial através de uma linguagem formal que permite expressar proposições complexas usando símbolos para constantes, funções, predicados e variáveis, bem como regras gramaticais para combinar esses símbolos e expressar quantificadores.

Ademais, a linguagem de primeira ordem também inclui operadores lógicos, como a negação, a conjunção, a disjunção, a implicação e a bi-implicação, que são usados para construir proposições mais complexas a partir de outras simples.

Por exemplo, podemos expressar a proposição "Se um animal é um gato, então ele é um mamífero" em LPO usando o operador de implicação, como "para todo x, se gato(x), então mamífero(x)". Isso indica que, para qualquer valor de x que seja um gato, a proposição "mamífero(x)" também é verdadeira.

A LPO permite a representação de conhecimento mais complexo do que a lógica proposicional, bem como possibilita a construção de sistemas de raciocínio mais sofisticados. Ela é amplamente utilizada em áreas como sistemas especialistas, sistemas de raciocínio, representação de conhecimento e inferência automatizada.

Um exemplo de aplicação da LPO em sistemas especialistas é a construção de um sistema para diagnóstico médico. Ele pode usar regras escritas em LPO para inferir diagnósticos com base em informações sobre os sintomas apresentados pelo paciente. Por exemplo, podemos ter a seguinte regra:

Se um paciente apresenta febre e dor de cabeça, então ele pode ter meningite.

Essa regra pode ser representada em LPO da seguinte forma:

"para todo x , se $\text{paciente}(x)$ e $\text{febre}(x)$ e $\text{dor_de_cabeca}(x)$, então $\text{meningite_possivel}(x)$ "

Nesta regra, " $\text{paciente}(x)$ ", " $\text{febre}(x)$ " e " $\text{dor_de_cabeca}(x)$ " são símbolos de predicado que representam as propriedades de ser um paciente, ter febre e dor de cabeça, respectivamente, e " $\text{meningite_possivel}(x)$ " é um símbolo de predicado que caracteriza a propriedade de ser possível ter meningite.

O sistema pode usar essa regra, com outras regras e fatos, para inferir um diagnóstico com base nas informações sobre os sintomas apresentados pelo paciente. Isso permite que o sistema identifique rapidamente possíveis doenças com base nos sintomas apresentados e ajuda os médicos a tomar decisões mais informadas.

Sintaxe e semântica da lógica de primeira ordem (LPO)

A sintaxe da lógica de primeira ordem (LPO) é baseada em termos, fórmulas bem formadas e quantificadores. Os termos podem ser constantes, variáveis e funções. As fórmulas bem formadas podem ser átomos, fórmulas moleculares, ou fórmulas complexas com operadores lógicos, quantificadores e conectivos. Os quantificadores, "para todo" e "existe", permitem generalizar sobre variáveis livres, o que significa que eles ligam variáveis às fórmulas e permitem afirmar algo sobre todos os objetos de um determinado domínio.

A semântica da LPO é dada por meio da interpretação de termos, predicados e quantificadores em um dado domínio de discurso. Cada interpretação atribui significado a todo símbolo em um domínio de discurso, e a partir disso, atribui um valor verdade para cada fórmula da LPO. As interpretações também permitem definir modelos, que são estruturas matemáticas que representam o domínio de discurso e que descrevem como as fórmulas são verdadeiras ou falsas nesse domínio.

Por exemplo, considere a seguinte fórmula da LPO:

"para todo x , se x é um número inteiro positivo, então x é maior que zero"

Essa fórmula afirma que todos os números inteiros positivos são maiores que zero. A semântica dela depende de como definimos o domínio de discurso e as interpretações dos símbolos envolvidos. Se o domínio de discurso é o conjunto dos números inteiros, e interpretamos "x é um número inteiro positivo" como "x é um número inteiro e x é maior que zero", então a fórmula será verdadeira. Se, por outro lado, interpretamos "x é um número inteiro positivo" como "x é um número inteiro e x é maior ou igual a zero", então a fórmula será falsa.

Utilização da lógica de primeira ordem

A lógica de primeira ordem (LPO) é amplamente utilizada na inteligência artificial (IA) para representação de conhecimento e raciocínio automatizado. Ela é capaz de expressar conceitos complexos, como objetos, classes, relações e funções, bem como permitir a quantificação sobre esses conceitos. Isso torna a LPO uma ferramenta poderosa para a construção de sistemas de IA que podem representar conhecimento em domínios específicos e inferir novas informações a partir dele.

A utilização da LPO na IA envolve a definição de um conjunto de axiomas e regras que descrevem o domínio de discurso em questão. Eles são escritos em uma linguagem formal, como a LPO, e podem ser usados por um motor de inferência para deduzir novas informações a partir das informações existentes. O motor de inferência é um componente central de muitos sistemas de IA, pois é responsável por aplicar as regras e axiomas a fim de obter conclusões a partir de fatos conhecidos.

A LPO é usada em muitas áreas da IA incluindo sistemas especialistas, representação de conhecimento, processamento de linguagem natural e robótica. Um exemplo de sua aplicação ocorre em sistemas de recomendação, onde a LPO pode ser usada para representar o perfil de um usuário, os itens recomendados e as relações entre eles. Com essa representação formal, o motor de inferência gera recomendações personalizadas com base no conhecimento representado.

Outra aplicação da LPO é na modelagem de sistemas complexos, como sistemas de controle de tráfego aéreo. Neles, a LPO pode ser usada para representar as restrições e regras de segurança que devem ser seguidas pelos aviões e controladores de tráfego aéreo. Com essa representação formal, o motor de inferência ajuda os controladores a tomar decisões seguras e eficientes em tempo real.



Saiba mais

A fim de compreender melhor sobre lógica de primeira ordem, recomendamos os capítulos 8 (Lógica de primeira ordem) e 9 (Inferência em lógica de primeira ordem) da seguinte obra:

RUSSELL, S.; NORVIG, P. *Inteligência artificial*. 3. ed. Barueri: Grupo GEN, 2013.

Engenharia de conhecimento em lógica de primeira ordem (LPO)

A engenharia de conhecimento em lógica de primeira ordem (LPO) na inteligência artificial (IA) envolve o processo de construção de sistemas de IA que utilizam a LPO como linguagem de representação de conhecimento e raciocínio. Trata-se de uma abordagem para o desenvolvimento de sistemas especialistas e outros sistemas de IA que se baseiam em conhecimento formalizado e regras de inferência.

O processo de engenharia de conhecimento em LPO começa com a identificação e análise do domínio do problema em questão. Isso envolve o reconhecimento dos conceitos relevantes, relações e funções que descrevem o domínio, bem como as regras e restrições que governam o comportamento dos elementos do domínio.

Com base na análise do domínio, os engenheiros de conhecimento desenvolvem uma ontologia que descreve os conceitos e relações relevantes do domínio em termos de axiomas formais da LPO. Essa ontologia é a base para o sistema de IA, e é usada para representar o conhecimento necessário para resolver problemas no domínio.

Uma ontologia é uma estrutura de conhecimento formal que descreve os conceitos, relações e propriedades que existem em um determinado domínio de conhecimento. Ela é usada para representar e organizar o conhecimento de forma que seja facilmente compreensível por humanos e computadores.

A construção de uma ontologia é um processo complexo e requer conhecimento especializado do domínio de conhecimento. Existem várias ferramentas e linguagens de ontologia disponíveis para auxiliar na construção de ontologias, como Protégé, OWL e RDF. Além disso, é importante que ela seja atualizada e revisada regularmente para garantir que continue sendo relevante e precisa para o domínio de conhecimento.



Saiba mais

A fim de entender melhor acerca da ontologia, recomenda-se a leitura do seguinte artigo:

FREITAS, F. L. *Ontologias e a Web Semântica*. Santos: Universidade Católica de Santos, 2007. Disponível em: <https://bit.ly/3JoXiku>. Acesso em: 6 mar. 2023.

Os engenheiros de conhecimento também desenvolvem uma base de regras que descreve como o conhecimento na ontologia pode ser combinado e inferido para produzir novas informações. Essas regras podem ser escritas em LPO e usadas por um motor de inferência para deduzir novas informações a partir daquelas já existentes.

Uma vez que a ontologia e as regras de inferência tenham sido definidas, o sistema de IA pode ser construído e testado em um ambiente controlado. O processo de construção envolve a implementação do motor de inferência, que usa a ontologia e as regras de inferência para resolver problemas no domínio. O sistema é então testado e refinado para melhorar sua precisão e eficácia.

Um modelo prático da utilização da LPO na engenharia de conhecimento em IA é a construção de um sistema especialista para diagnóstico médico. Nesse caso, a ontologia do sistema incluiria conceitos como doenças, sintomas, tratamentos e fatores de risco, bem como as relações entre eles. As regras de inferência poderiam descrever como combinar informações sobre os sintomas de um paciente para identificar possíveis doenças e prescrever tratamentos apropriados.

Outro exemplo é o desenvolvimento de um sistema de recomendação de filmes. No caso, a ontologia do sistema incluiria informações sobre filmes, gêneros, diretores e atores, assim como as relações entre eles. As regras de inferência poderiam ser usadas para recomendar filmes com base nas preferências do usuário, levando em consideração fatores como gênero, diretor e atores favoritos.

A LPO também é usada em sistemas de processamento de linguagem natural, nos quais a ontologia é empregada para representar o significado de palavras e frases, e as regras de inferência são utilizadas a fim de entender e responder a perguntas e comandos em linguagem natural.

Na robótica, a LPO é usada para representar o conhecimento sobre o ambiente do robô, incluindo objetos, locais e eventos, bem como as relações entre eles. As regras de inferência podem ser usadas para ajudar o robô a tomar decisões com base em sua percepção do ambiente.



Figura 35

Disponível em: <https://bit.ly/3EYLW48>. Acesso em: 6 mar. 2023.

5.3 Inferência em lógica de primeira ordem

Inferência em lógica de primeira ordem é o processo de deduzir conclusões a partir de um conjunto de premissas na forma de cláusulas. Esse processo é executado por meio da aplicação de regras de inferência, que determinam como as cláusulas podem ser combinadas e manipuladas para gerar novas cláusulas ou inferências.

O objetivo da inferência em lógica de primeira ordem na IA é automatizar o processo de raciocínio e tomada de decisão em sistemas de conhecimento baseados em LPO. Isso é feito por meio de mecanismos de inferência que podem ser incorporados em sistemas especialistas, agentes inteligentes, sistemas de recomendação e outros aplicativos de IA que envolvem raciocínio sobre informações complexas.

Existem vários tipos de regras de inferência que podem ser usados na LPO, incluindo regras de resolução, regras de unificação e regras de substituição. A resolução é uma técnica de inferência que envolve a aplicação de uma regra de inferência para duas cláusulas, resultando em uma nova cláusula que é a resolução das duas originais. A unificação é uma técnica que envolve a identificação de termos comuns em duas cláusulas, o que permite que elas sejam combinadas em uma única. A substituição é uma técnica que envolve a troca de uma variável por um termo mais específico em uma cláusula, com base em uma regra de inferência.

A inferência em LPO é uma área de pesquisa ativa na inteligência artificial e continua a evoluir com a descoberta de novos métodos e técnicas. Ela é fundamental para a construção de sistemas inteligentes que podem raciocinar e tomar decisões com base em informações complexas e heterogêneas.

Outras técnicas de inferência em LPO incluem a resolução paramétrica, a unificação dirigida e a subexemplo. A resolução paramétrica é uma extensão da resolução que permite que as variáveis sejam substituídas por fórmulas complexas, em vez de termos simples. A unificação dirigida é uma técnica que envolve a tentativa de unificar as cláusulas de maneira específica, com o objetivo de evitar a explosão combinatória de possibilidades de unificação. A subexemplo é uma técnica que inclui a identificação de um subconjunto de variáveis e termos em uma cláusula que são relevantes para um determinado problema.

A inferência em LPO é usada em uma variedade de aplicativos de IA incluindo sistemas especialistas, agentes inteligentes e sistemas de recomendação. Em sistemas especialistas, a inferência é usada para derivar respostas para perguntas complexas com base em um conjunto de regras de conhecimento. Em agentes inteligentes, a inferência é empregada para tomar decisões em ambientes dinâmicos e incertos, com base em informações sensoriais e conhecimento prévio. Em sistemas de recomendação, a inferência é utilizada para gerar recomendações personalizadas com base em preferências e históricos de interação do usuário.

Inferência proposicional versus inferência de primeira ordem

A inferência proposicional e a inferência de primeira ordem são duas técnicas fundamentais de raciocínio em lógica matemática e inteligência artificial. A seguir, apresentamos algumas diferenças entre esses dois tipos de inferência:

- **Escopo de expressividade:** a lógica proposicional é limitada à expressão de proposições simples e relacionamentos entre elas, enquanto a lógica de primeira ordem permite a expressão de proposições complexas envolvendo quantificação e relacionamentos entre objetos e predicados.
- **Flexibilidade semântica:** a lógica proposicional é inflexível em relação às possíveis interpretações semânticas, enquanto a lógica de primeira ordem é capaz de lidar com diferentes interpretações semânticas, permitindo o uso de variáveis quantificadas e fórmulas abertas.
- **Eficiência computacional:** a inferência proposicional é computacionalmente mais eficiente do que a inferência de primeira ordem, já que requer menos operações de processamento de dados. Por outro lado, a inferência de primeira ordem é mais expressiva e flexível, permitindo lidar com problemas mais complexos.
- **Reusabilidade de conhecimento:** a lógica proposicional é mais fácil de aplicar em diferentes domínios de conhecimento, mas é menos reutilizável do que a lógica de primeira ordem. A lógica de primeira ordem permite a construção de ontologias e sistemas de conhecimento mais abrangentes e reutilizáveis em diferentes domínios.

Em resumo, a inferência proposicional e a inferência de primeira ordem têm vantagens e desvantagens, dependendo do domínio de aplicação. A proposicional é mais adequada para problemas simples e bem definidos, enquanto a de primeira ordem é mais adequada para problemas complexos e mal definidos.

Unificação e inferência de primeira ordem

Unificação é uma técnica utilizada na lógica de primeira ordem para encontrar substituições que tornem duas fórmulas logicamente equivalentes. Trata-se de um passo fundamental em muitos algoritmos de inferência automatizada, incluindo a resolução de predicados, o algoritmo de Robinson e o algoritmo de Herbrand.

A inferência de primeira ordem é um processo de raciocínio que envolve a derivação de novas fórmulas a partir de outras existentes, utilizando regras de inferência e técnicas de unificação. Ela é amplamente utilizada em sistemas de lógica artificial, sistemas de representação do conhecimento e sistemas de raciocínio automatizados.

O processo de inferência de primeira ordem começa com um conjunto de fórmulas conhecidas, chamadas de premissas. Ela usa regras de inferência para derivar novas fórmulas a partir dessas premissas. Essas novas fórmulas são então adicionadas ao conjunto de premissas, e o processo é repetido até que não seja possível inferir novas fórmulas.

A unificação é uma técnica importante para a inferência de primeira ordem, porque permite encontrar substituições que tornam duas fórmulas equivalentes. Por exemplo, se tivermos as fórmulas " $P(x)$ " e " $P(a)$ ", podemos unificá-las, substituindo " x " por " a ", para obter a fórmula " $P(a)$ ". A unificação é usada para agrupar fórmulas durante a aplicação de regras de inferência, como a resolução de predicados e a eliminação de quantificadores.

Uma das principais diferenças entre a inferência proposicional e a inferência de primeira ordem é que, enquanto a inferência proposicional lida com fórmulas atômicas, a inferência de primeira ordem lida com fórmulas mais complexas, que contêm variáveis, quantificadores e predicados. Isso permite que a inferência de primeira ordem seja mais expressiva e, portanto, mais útil em muitos problemas de inteligência artificial.

Um exemplo de problema em que a inferência de primeira ordem é particularmente útil é o problema de planejamento, que envolve a geração de planos de ação para alcançar um determinado objetivo em um dado domínio. Nesse caso, ela pode ser usada para representar as ações e estados do domínio, bem como as restrições que devem ser atendidas para que um plano seja válido. A partir dessas representações, pode-se aplicar a inferência de primeira ordem para gerar planos de ação viáveis.

Ela também é usada em sistemas de raciocínio automatizado, como o Prolog, que é uma linguagem de programação baseada em lógica de primeira ordem. O Prolog permite que os programadores representem o conhecimento em forma de fatos e regras e utilizem a inferência de primeira ordem para responder a consultas sobre esse conhecimento.

Encadeamento para frente

O encadeamento para frente, também conhecido como encadeamento direto ou encadeamento progressivo, é um método de inferência utilizado em sistemas baseados em conhecimento da inteligência artificial. Ele começa com um conjunto de fatos conhecidos e regras, e tenta deduzir novos fatos ou conclusões a partir daí. O encadeamento para frente trabalha iterativamente a partir dos fatos conhecidos e aplica as regras para gerar novas informações, até que uma resposta seja encontrada ou não haja mais regras a serem aplicadas.

O processo de encadeamento para frente geralmente começa com um conjunto de fatos iniciais, que são representados na forma de base de conhecimento. Em seguida, o sistema aplica as regras apropriadas a esses fatos para gerar novas informações. Esses novos dados são então adicionados à base de conhecimento e o processo é repetido até que uma resposta seja encontrada.

Um exemplo simples de encadeamento para frente é o seguinte: suponha que temos um sistema de diagnóstico médico que usa uma base de conhecimento para determinar a doença de um paciente. A base de conhecimento contém fatos sobre os sintomas que o paciente apresenta e regras que relacionam esses sintomas a doenças. O encadeamento para frente começaria com os sintomas conhecidos do paciente e aplicaria as regras apropriadas para deduzir a doença que o indivíduo tem.

O encadeamento para frente é adequado para situações em que a resposta desejada é conhecida e pode ser obtida a partir dos fatos iniciais e das regras. No entanto, o método pode ser ineficiente em casos em que há muitas regras a serem aplicadas ou quando a base de conhecimento é muito grande. Neles, outros métodos de inferência, como o encadeamento para trás ou o método de resolução, podem ser mais eficientes.

Outra característica do encadeamento para frente é ele geralmente ser usado em sistemas em que o conhecimento é adquirido de forma incremental. Isso significa que novas regras e fatos podem ser adicionados à base de conhecimento à medida que se tornam disponíveis. Ele é então empregado para atualizar a base de conhecimento e inferir novas informações a partir dos novos dados.

O encadeamento para frente pode ser implementado de várias maneiras, desde sistemas de produção simples até outros mais complexos que usam lógica de primeira ordem ou outras representações de conhecimento. Uma das limitações do encadeamento para frente é que ele pode levar a erros se as regras forem mal definidas ou se houver informações incompletas ou contraditórias na base de conhecimento. Além disso, ele pode levar a uma explosão combinatória de possíveis inferências, o que torna o processo muito lento ou ineficiente em algumas situações.

Encadeamento para trás

O encadeamento para trás (ou backward chaining, em inglês) é um método de inferência utilizado em sistemas baseados em conhecimento da inteligência artificial. Ao contrário do encadeamento para frente, que começa com fatos conhecidos e regras e tenta deduzir novas informações a partir deles, o encadeamento para trás começa com a hipótese que se deseja provar e trabalha "para trás" para encontrar fatos e regras que possam levar à conclusão desejada.

Ele é particularmente útil em sistemas de diagnóstico e planejamento nos quais o objetivo seja determinar quais ações devem ser tomadas para atingir uma meta específica. Por exemplo, se o objetivo for fazer um bolo, o encadeamento para trás poderia começar com a hipótese de que o bolo precisa ser assado e, em seguida, trabalhar "para trás" a fim de determinar quais ingredientes e utensílios são necessários, bem como quais etapas têm ser seguidas para prepara-lo e assá-lo.

O encadeamento para trás pode ser implementado de várias maneiras, desde sistemas de produção simples até outros mais complexos que usam lógica de primeira ordem ou demais representações de conhecimento. Uma de suas vantagens é que ele pode ser mais eficiente do que o encadeamento para frente em algumas situações, especialmente quando há muitas regras a serem aplicadas ou a base de conhecimento é muito grande.

No entanto, assim como no encadeamento para frente, o encadeamento para trás pode levar a erros se as regras forem mal definidas ou se houver informações incompletas ou contraditórias na base de conhecimento. Além disso, ele pode levar a várias soluções possíveis, o que dificulta a escolha da solução ideal.

Resolução

Resolução é uma técnica de inferência em lógica de primeira ordem usada para inferir novas cláusulas a partir de um conjunto de outras existentes. A técnica envolve a unificação de duas cláusulas para produzir uma nova.

Trata-se de uma técnica importante no campo da inteligência artificial, usada em sistemas de raciocínio automatizado, verificação de software, diagnóstico médico e em muitas outras aplicações. É particularmente útil em tarefas que envolvem a prova de teoremas e verificação formal de sistemas, quando é necessário determinar se um conjunto de axiomas ou regras pode ser usado para inferir uma certa conclusão.

Ela pode ser aplicada em vários tipos de lógica de primeira ordem, incluindo a lógica proposicional e a lógica de primeira ordem de Horn. A resolução é geralmente usada em combinação com outras técnicas de inferência, como o encadeamento para trás, para permitir que os sistemas de IA determinem se uma conclusão pode ser inferida a partir de um conjunto de premissas ou fatos dados.

Para entender como a resolução funciona em lógica de primeira ordem, é importante compreender o que é uma cláusula. Cláusula é uma disjunção de literais em que um literal é uma fórmula atômica ou sua negação. Por exemplo, a cláusula $(A \text{ ou não } B \text{ ou } C)$ é uma disjunção de três literais: A , não B e C .

A resolução envolve a unificação de duas cláusulas, o que significa encontrar uma substituição que faça com que elas se tornem idênticas em uma determinada variável. Trata-se de uma operação que procura uma substituição comum que possa ser aplicada a duas fórmulas para torná-las iguais. Por exemplo, as fórmulas $P(x, y)$ e $P(a, b)$ podem ser unificadas por uma substituição que associa x com a e y com b .

Ela é usada para inferir novas cláusulas a partir de outras existentes. Para fazer isso, é necessário encontrar duas cláusulas que possam ser unificadas por uma substituição e que possuam complementos entre si. Elas são chamadas de cláusulas resolvíveis. A partir daí, é possível inferir uma nova cláusula que seja a disjunção dos literais restantes das cláusulas originais.

Por exemplo, suponha que temos as seguintes cláusulas:

- **Cláusula 1:** $P(x) \text{ ou } Q(x)$
- **Cláusula 2:** não $Q(a)$ ou R

Podemos unificá-las usando a substituição $\{x/a\}$ para obter:

- **$P(a)$ ou R**

Trata-se de uma nova cláusula que conseguimos adicionar ao nosso conjunto de cláusulas existentes.

A resolução é uma técnica poderosa, mas pode ser difícil de aplicar de forma eficiente em problemas complexos. A eficiência é melhorada usando várias heurísticas e técnicas de otimização, como a poda de subproblemas irrelevantes para a solução de um problema específico.

Na resolução, um problema é formulado acerca de uma teoria de lógica de primeira ordem, transformando-a em uma cláusula. Essa, por sua vez, é então resolvida com outras cláusulas, levando à obtenção de uma cláusula vazia ou à interrupção do processo de resolução, fato que permite provar teoremas em sistemas de lógica de primeira ordem. A resolução é um método utilizado em sistemas de prova automatizados, como o Prolog. Ele possibilita que um programa prove a verdade de uma proposição, gerando uma sequência de inferências logicamente válidas.

Um exemplo prático de resolução na lógica de primeira ordem é a seguinte proposição:

- Todos os homens são mortais.
- Sócrates é um homem.
- Portanto, Sócrates é mortal.

Essa proposição pode ser formalizada na lógica de primeira ordem. Suponha que o domínio seja o conjunto de todos os seres humanos, e que $H(x)$ seja a proposição "x é um homem" e $M(x)$ seja a proposição "x é mortal". Podemos formalizar a proposição como:

$$\forall x (H(x) \rightarrow M(x))$$

$$H(\text{Sócrates})$$

$$\text{Portanto, } M(\text{Sócrates})$$

Para provar essa proposição usando resolução, podemos negar a conclusão e adicionar sua negação às premissas existentes. Então, podemos aplicar a regra de resolução para simplificar a fórmula. A seguir, mostraremos as etapas do processo:

- $\neg M(\text{Sócrates})$ (negação da conclusão)
- $H(\text{Sócrates})$ (premissa 2)
- $\forall x (H(x) \rightarrow M(x))$ (premissa 1)
- $H(\text{Sócrates}) \rightarrow M(\text{Sócrates})$ (tradução da premissa 3)
- $\neg H(\text{Sócrates}) \vee M(\text{Sócrates})$ (tradução da premissa 4)

- $M(\text{Sócrates}) \vee \neg H(\text{Sócrates})$ (comutatividade da disjunção em 5)
- $\neg H(\text{Sócrates})$ (eliminação da disjunção em 6, já que $\neg M(\text{Sócrates})$ é verdadeiro)
- Contradição (resolução entre 7 e 2)

Como a resolução levou à obtenção de uma cláusula vazia (contradição), podemos concluir que a proposição é verdadeira. Portanto, inferimos que Sócrates é mortal.

6 REPRESENTAÇÃO DO CONHECIMENTO

O conhecimento é um aspecto fundamental da inteligência artificial (IA), sendo usado em várias tarefas, como reconhecimento de padrões, aprendizado de máquina, planejamento, diagnóstico e outras. Ele pode ser adquirido de fontes externas, como bases de dados ou especialistas humanos, ou ser aprendido através da interação com o ambiente.

Um sistema de reconhecimento de padrões é composto das seguintes etapas: aquisição de dados; pré-processamento, que consiste na eliminação de ruídos ou distorções dos dados adquiridos; extração de características (ou atributos), em que criamos um vetor de características com dados extraídos dos objetos adquiridos, reduzindo os dados a atributos, propriedades ou características; triagem de características, que analisa o conjunto de características e exclui as mais redundantes; e classificador, que toma uma certa decisão baseando-se na análise de um padrão (DUDA; HART; STORK, 2000). O classificador analisa um conjunto de treinamento com exemplos de todas as classes existentes no sistema, e toma decisões baseando-se no aprendizado dessa análise.

Existem várias formas de representar conhecimento na IA, incluindo regras de produção, ontologias, mapas conceituais e grafos de conhecimento. As regras de produção são estruturas de conhecimento que consistem em condições e ações. As ontologias são modelos de conhecimento que descrevem a estrutura conceitual de um domínio específico. Os mapas conceituais são diagramas que representam relações entre conceitos. Os grafos de conhecimento são estruturas de dados que caracterizam relações entre entidades.

A aquisição de conhecimento é uma tarefa importante na IA, pois permite que os agentes inteligentes aprendam novos conceitos e relações sem serem explicitamente programados. Existem vários métodos para adquirir conhecimento, incluindo aprendizado supervisionado, aprendizado não supervisionado e aprendizado por reforço.

O aprendizado supervisionado é um método de aprendizado de máquina em que um agente é treinado com dados rotulados. Já o aprendizado não supervisionado é um método de aprendizado de máquina em que um agente é treinado com dados não rotulados. Por fim, o aprendizado por reforço é um método de aprendizado de máquina em que um agente é treinado através de recompensas e punições.

O conhecimento é um aspecto importante na IA, pois permite que os agentes inteligentes tomem decisões melhores e resolvam problemas de forma mais eficiente. Sua representação adequada é

importante para o desempenho e a eficiência dos agentes inteligentes, e a aquisição de conhecimento é uma tarefa fundamental para tornar os agentes mais inteligentes.

6.1 Aquisição do conhecimento

A aquisição do conhecimento é o processo de adquirir, representar e organizar informações para que possam ser usadas pelos sistemas de inteligência artificial. Isso inclui tanto a coleta de dados quanto a sua interpretação e organização.



Figura 36

Disponível em: <https://bit.ly/41TLKgw>. Acesso em: 6 mar. 2023.

Métodos de aquisição do conhecimento

Existem vários métodos utilizados para a aquisição de conhecimento em inteligência artificial, alguns dos principais incluem:

- **Aprendizado automático:** processo de adquirir conhecimento a partir de dados utilizando algoritmos de aprendizado de máquina.
- **Inferência lógica:** processo de adquirir conhecimento a partir de inferências baseadas em regras lógicas.
- **Raspagem de dados:** processo de coletar dados de fontes na internet, como sites, redes sociais, e bancos de dados.
- **Aquisição de conhecimento de fontes humanas:** especialistas, livros, artigos científicos, entrevistas etc.

- **Aprendizado de reforço:** processo de adquirir conhecimento através de tentativa e erro, sendo que o sistema aprende a partir de suas ações e suas consequências.
- **Aprendizado por demonstração:** processo de adquirir conhecimento através de exemplos, sendo que o sistema aprende a partir da observação de ações humanas.
- **Aprendizado por observação:** processo de adquirir conhecimento através da observação de um ambiente sem intervenção direta.
- **Aprendizado por exploração:** processo de adquirir conhecimento através da exploração ativa do ambiente.

Cada um desses métodos tem suas próprias vantagens e desvantagens, e é frequentemente combinado com outros para aumentar a eficiência e precisão da aquisição de conhecimento.

Entrevistas não estruturadas

Entrevistas não estruturadas são uma técnica de coleta de dados utilizada para adquirir conhecimento de fontes humanas. Elas são chamadas de não estruturadas porque não seguem um roteiro fixo de perguntas, permitindo que o entrevistado responda livremente e forneça informações adicionais que podem não ter sido previstas. Elas são usadas para coletar informações qualitativas, como opiniões, crenças, motivações e percepções, sendo geralmente realizadas por meio de conversas informais e conduzidas por pesquisadores ou entrevistadores com habilidades específicas. Costumam ser usadas em campos como psicologia, sociologia, antropologia e estudos de mercado.

Entrevistas estruturadas

Entrevistas estruturadas são uma técnica de coleta de dados que segue um roteiro fixo de perguntas. Essas perguntas são previamente planejadas e testadas, sendo feitas para todos os participantes da entrevista. São úteis para coletar dados quantitativos e comparáveis, pois as questões são formuladas de forma a serem respondidas de forma objetiva. Elas podem ser realizadas por meio de questionários escritos ou entrevistas face a face, sendo frequentemente usadas em campos como estatística, ciências sociais e psicologia. Além disso, são mais objetivas e menos suscetíveis a viés de interpretação do que as entrevistas não estruturadas.

Estudo de caso

Um estudo de caso em inteligência artificial é uma técnica utilizada para investigar e compreender um sistema ou problema específico. Ele geralmente envolve a coleta de dados a partir de uma variedade de fontes, como entrevistas, registros, observações, e análise de documentos. Seu objetivo é fornecer uma descrição detalhada e compreensiva do sistema ou problema em questão. Estudos de caso são comumente usados para avaliar a eficácia de sistemas de inteligência artificial, identificar problemas e melhorias, e fornecer exemplos de como a tecnologia pode ser aplicada em um contexto específico. Por

fim, têm a função de desenvolver e testar hipóteses, identificar tendências e padrões, e propor soluções para problemas específicos.

Descoberta de conhecimento em base de dados

Descoberta de conhecimento em base de dados (KDD, do inglês Knowledge Discovery in Databases) é o processo de identificar padrões e relações significativas em grandes conjuntos de dados. Trata-se de uma abordagem interdisciplinar que combina técnicas de estatística, aprendizado de máquina, mineração de dados e banco de dados para extrair informações úteis e valiosas a partir de dados brutos. Seu objetivo é transformar grandes quantidades de dados não estruturados em informações estruturadas e úteis que possam ser usadas para tomar decisões. A KDD é amplamente utilizada em aplicações como marketing, finanças, saúde e segurança, e pode ser usada para identificar tendências, prever eventos futuros e melhorar a eficiência de processos empresariais.

Métodos de representação de conhecimento

Em inteligência artificial, os métodos de representação de conhecimento são técnicas utilizadas para representar e armazenar informações de maneira que possam ser processadas e compreendidas pelos sistemas de inteligência artificial. Alguns dos métodos mais comuns incluem:

- **Representação baseada em regras:** representação de conhecimento que se baseia em regras lógicas e condicionais.
- **Representação baseada em frames:** representação de conhecimento que se baseia em estruturas de dados chamadas frames, que contêm informações sobre um objeto ou conceito.
- **Representação baseada em ontologias:** representação de conhecimento que se baseia em ontologias, que são modelos de conceitos e relações que descrevem um domínio específico.
- **Representação baseada em redes neurais:** representação de conhecimento que se baseia em redes neurais, que são modelos matemáticos inspirados na estrutura do cérebro humano e capazes de aprender e generalizar a partir de exemplos.
- **Representação baseada em sistemas fuzzy:** representação de conhecimento que se baseia em lógica fuzzy, que permite lidar com incertezas e imprecisões.
- **Representação baseada em lógica probabilística:** representação de conhecimento que se baseia em lógica probabilística, que permite lidar com incertezas e imprecisões.

Cada um desses métodos tem suas próprias vantagens e desvantagens, e é frequentemente combinado com outros para aumentar a eficiência e precisão da representação de conhecimento.

Lógica

Lógica é uma disciplina matemática e filosófica que estuda as propriedades formais de proposições e inferências. Ela é usada para formalizar e analisar argumentos e inferências lógicas. Em inteligência artificial, a lógica é usada para representar e manipular o conhecimento, para inferir novas informações a partir de informações conhecidas, e para construir sistemas de inferência automática. A lógica proposicional é a forma mais simples de lógica e é usada para representar relações lógicas entre proposições simples. A lógica de primeira ordem é uma forma mais avançada de lógica e permite a representação de relações lógicas entre proposições e objetos. A lógica probabilística é uma forma especializada de lógica que possibilita lidar com incertezas e imprecisões, sendo muito utilizada em sistemas de inferência baseados em evidência.

Redes

Redes são estruturas de dados utilizadas para representar relações e interações entre diferentes elementos. Elas podem ser usadas para caracterizar diversos tipos de relações, tais como relações semânticas entre palavras, relações causais entre eventos, relações topológicas entre objetos, entre outras, sendo frequentemente empregadas para representar e processar informações complexas de maneira estruturada e eficiente.

Existem vários tipos de redes, como redes neurais, redes bayesianas, redes markovianas, redes sociais, entre outros. Redes neurais são inspiradas na estrutura do cérebro humano e usadas para aprender e generalizar a partir de exemplos. Redes bayesianas são usadas para modelar incertezas e probabilidades. Já as redes markovianas são utilizadas para modelar processos estocásticos e sistemas dinâmicos. Por fim, as redes sociais são empregadas para modelar e analisar relações entre indivíduos ou entidades em um sistema social.

Redes bayesianas

Redes bayesianas (também conhecidas como redes de probabilidade ou modelos de Bayes) são modelos gráficos probabilísticos que permitem a representação e o raciocínio sobre a incerteza em sistemas complexos.

Elas são baseadas na teoria de probabilidade bayesiana, que é uma abordagem matemática para quantificar a incerteza por meio da atualização de probabilidades com base em novas informações. Esses modelos são representados por um grafo direcionado acíclico em que os nós representam as variáveis do sistema e as arestas as relações de dependência entre essas variáveis.

As redes bayesianas são usadas para modelar sistemas em que as variáveis estão interconectadas de maneira complexa e há incerteza em relação ao estado dessas variáveis. Por exemplo, podem ser usadas para modelar o risco de doenças em uma população em que as variáveis incluem idade, histórico médico, estilo de vida e outros fatores que influenciam o risco de uma pessoa desenvolver determinada doença.

Elas permitem a inferência probabilística, ou seja, a capacidade de responder a perguntas probabilísticas sobre o sistema modelado. Por exemplo, uma rede bayesiana pode ser usada para responder a perguntas como "Qual é a probabilidade de uma pessoa ter uma determinada doença, dadas as suas características e histórico médico?" ou "Qual é a probabilidade de uma pessoa ter determinado atributo, dadas outras características conhecidas?"

Redes markovianas

Redes markovianas (também conhecidas como processos de Markov) são modelos estocásticos amplamente usados em ciência da computação, matemática, física, biologia, economia e outras áreas para descrever a evolução temporal de sistemas complexos que exibem comportamento aleatório.

Rede markoviana é um modelo matemático que descreve a probabilidade de transição entre estados de um sistema, uma vez que a probabilidade de transição depende apenas do estado atual e não dos anteriores. Em outras palavras, a propriedade fundamental de um processo de Markov é a propriedade de Markov, que afirma que o futuro é independente do passado, dado o presente.

As redes markovianas têm a função de modelar sistemas em que as transições entre estados são aleatórias, mas seguem certas regras probabilísticas. Por exemplo, podem ser usadas para modelar a evolução temporal de uma população de animais, em que o número de animais em uma determinada época é influenciado por fatores aleatórios, como a mortalidade e a reprodução, mas eles seguem certas regras probabilísticas.

Elas são úteis para prever o comportamento futuro de um sistema, calcular estatísticas importantes, como a probabilidade de um evento ocorrer em um determinado momento, e otimizar a tomada de decisão em sistemas complexos. Algoritmos de aprendizado de máquina baseados em redes markovianas, como o algoritmo de Monte Carlo e o algoritmo de cadeia de Markov, são empregados em inteligência artificial e processamento de linguagem natural.

O algoritmo de Monte Carlo é um método estatístico cuja função é estimar o valor de uma grandeza desconhecida por meio da geração de amostras aleatórias. Ele recebe esse nome em homenagem à cidade de Monte Carlo, em Mônaco, que é conhecida por seus cassinos e jogos de azar.

O algoritmo é usado em diversas aplicações, como física, matemática, engenharia, finanças e outras áreas, nos casos em que é difícil ou impossível obter uma solução analítica para um problema. A ideia central do método é gerar muitas amostras aleatórias do sistema em estudo e, em seguida, usá-las para estimar o valor de uma grandeza desconhecida.

Por exemplo, imagine que você queira estimar a área de um círculo com raio R . Uma forma de fazê-lo é gerar muitos pontos aleatórios em um quadrado de lado $2R$, que circunscreve o círculo. Em seguida, conte quantos pontos caem no círculo e quantos saem dele. A razão entre o número de pontos no círculo e o número total de pontos gerados dá a estimativa da área do círculo.

O algoritmo de Monte Carlo pode ser usado em problemas mais complexos, como simulações de sistemas físicos ou estimativas de valores de opções financeiras. Para aplicar o método, é necessário escolher uma distribuição aleatória apropriada a fim de gerar as amostras e uma técnica de análise dos dados gerados.

Frames

Frames em inteligência artificial são uma forma de representação de conhecimento que descreve objetos, conceitos ou eventos de um determinado domínio. Eles são compostos de atributos e valores que representam as características de um objeto ou conceito, e relações entre os objetos ou conceitos.

Os frames são uma forma de representar conhecimento especializado e fornecer estrutura para organizar e recuperar informações de maneira eficiente. Eles são utilizados para caracterizar conhecimento especializado e comumente atuam nos sistemas de inteligência artificial que lidam com tarefas de processamento de linguagem natural, reconhecimento de objetos, diagnóstico, entre outras. Seu uso permite modelar o conhecimento de um domínio específico de forma estruturada e fácil de ser acessado e empregado pelos sistemas de inteligência artificial.

Árvores de decisão

Árvores de decisão são técnicas de aprendizado de máquina supervisionado utilizadas para classificação e tomada de decisão. Elas são compostas de nós de decisão e nós de folha, sendo que cada nó de decisão representa uma decisão ou uma característica do problema, enquanto o nó de folha caracteriza uma classe ou uma decisão final. A construção de uma árvore de decisão começa com o nó raiz, que representa a característica mais importante para classificar os dados, e os nós subsequentes são construídos recursivamente, dependendo das características dos dados e das decisões tomadas nos nós anteriores.

Elas são utilizadas em aplicações como diagnóstico médico, análise de crédito, detecção de fraudes, entre outras. São fáceis de entender e interpretar, o que as torna úteis em muitas áreas, como medicina, finanças e marketing.

Ontologias

Ontologia é um campo da inteligência artificial que se concentra na representação e organização do conhecimento. Ela envolve a criação de uma estrutura hierárquica de conceitos e relações entre eles, chamada de ontologia. Essa estrutura é utilizada para representar de modo formal e precisa o conhecimento de um determinado domínio ou área. As ontologias têm diversas aplicações, como sistemas de recuperação de informação, inteligência artificial distribuída, robótica, e inteligência artificial baseada em agentes.

Para construir uma ontologia, é necessário seguir algumas etapas:

- 1) **Definir o domínio de conhecimento:** a ontologia deve ser construída para representar o conhecimento de um domínio específico, como medicina, finanças, ciência da computação, entre outros.
- 2) **Identificar os conceitos:** os conceitos são as entidades que existem no domínio de conhecimento e precisam ser representados na ontologia. É importante definir claramente cada conceito, identificando suas características e propriedades.
- 3) **Estabelecer as relações:** as relações são as formas pelas quais os conceitos estão relacionados entre si. É importante definir claramente cada relação e identificar as propriedades e características que elas possuem.
- 4) **Criar uma estrutura de classes:** a estrutura de classes é a hierarquia de conceitos que existem na ontologia. É importante criar uma hierarquia clara e organizada para facilitar a compreensão e a navegação na ontologia.
- 5) **Determinar as instâncias:** as instâncias são exemplos concretos de conceitos que existem na ontologia. É importante determinar as instâncias relevantes para o domínio de conhecimento e incluí-las na ontologia.
- 6) **Validar a ontologia:** a ontologia deve ser validada para garantir que está correta e consistente. Isso pode ser feito por meio de testes e revisões por especialistas do domínio de conhecimento.

6.2 Representação do conhecimento e raciocínio

A representação do conhecimento é uma tarefa fundamental na inteligência artificial (IA), pois permite que os agentes inteligentes armazenem, acessem e utilizem o conhecimento de forma eficiente. Existem várias formas de representar o conhecimento na IA, cada uma com suas vantagens e desvantagens.

Uma das formas mais comuns de representação do conhecimento é através de regras de produção. Elas consistem em uma condição e uma ação, e são usadas para representar relações lógicas entre conceitos. Por exemplo, uma regra de produção pode ser "Se o animal é um cachorro, então ele é um mamífero".

Outro modo comum de representação do conhecimento é através de ontologias, que são modelos de conhecimento que descrevem a estrutura conceitual de um domínio específico. Elas são compostas de conceitos, propriedades e relações e usadas para representar o conhecimento de forma estruturada e consistente.

Os mapas conceituais são outra forma de representação de conhecimento e consistem em diagramas que representam relações entre conceitos. Eles são usados para caracterizar o conhecimento de forma visual e intuitiva.

Os grafos de conhecimento representam conhecimento através de estruturas de dados que caracterizam relações entre entidades. Eles são usados para estabelecer o conhecimento de forma estruturada e flexível.

A representação do conhecimento permite que os agentes inteligentes armazenem, acessem e utilizem o conhecimento de forma eficiente. Sua escolha adequada é crucial para o desempenho e a eficiência dos agentes inteligentes, e deve ser adaptada para cada problema específico.

A representação do raciocínio possibilita que os agentes inteligentes tomem decisões e resolvam problemas de forma eficiente. Existem várias formas de representar o raciocínio na IA, cada uma com suas vantagens e desvantagens.

Uma forma comum de representação do raciocínio acontece através de lógica formal. Ela representa o raciocínio que utiliza símbolos e regras para caracterizar proposições e inferências lógicas. A lógica proposicional e a lógica de primeira ordem são exemplos de lógicas formais amplamente utilizadas na IA.

Outra forma de representação do raciocínio se dá por meio de redes neurais. As redes neurais são modelos computacionais inspirados em como o cérebro humano processa informações, sendo usadas para representar e inferir relações entre entrada e saída. Elas são amplamente utilizadas em tarefas de reconhecimento de padrões e aprendizado de máquina.

As redes bayesianas são outra forma de representação do raciocínio, que combina probabilidade e lógica para representar relações entre eventos. Elas são usadas para representar o raciocínio probabilístico, onde são levadas em conta as incertezas e as variações.

6.3 Linguagens e técnicas para aquisição

As linguagens para aquisição de conhecimento são ferramentas utilizadas na inteligência artificial (IA) para representar e adquirir conhecimento de forma estruturada e eficiente. Existem várias linguagens para essa aquisição, cada uma com suas características e aplicações.

Uma das mais comuns é a lógica formal. Ela representa o conhecimento que utiliza símbolos e regras para caracterizar proposições e inferências lógicas. A lógica proposicional e a lógica de primeira ordem são exemplos de lógicas formais.

Outra linguagem comum para aquisição de conhecimento é a linguagem de ontologia, especificamente utilizada para representar ontologias, que são modelos de conhecimento que descrevem a estrutura conceitual de um dado domínio. Ela é amplamente empregada em tarefas de recuperação de informação e inteligência artificial semântica.

A linguagem de descrição de objetos (ODL) é outra linguagem comum para aquisição de conhecimento, sendo usada para representar o conhecimento de forma estruturada, utilizada em sistemas de recuperação de informação, inteligência artificial e outras áreas.

6.4 Sistemas baseados em conhecimento

Os sistemas baseados em conhecimento são uma subárea da inteligência artificial (IA) que se concentra na representação, aquisição e utilização do conhecimento para fornecer inteligência aos agentes. Eles utilizam conhecimento estruturado, como ontologias, regras e lógica, para representar o conhecimento e inferir novos dados.

Os sistemas baseados em conhecimento são compostos de vários componentes, incluindo:

- **Mecanismos de inferência:** permitem inferir novas informações a partir do conhecimento existente.
- **Representação do conhecimento:** permite representar o conhecimento de forma estruturada e eficiente.
- **Mecanismos de explicação:** permitem explicar as inferências feitas pelo sistema.
- **Mecanismos de adição de conhecimento:** permitem adicionar novo conhecimento ao sistema.

Os sistemas baseados em conhecimento são utilizados em várias áreas, como recuperação de informação, robótica, inteligência artificial baseada em regras, inteligência artificial semântica, entre outros. Eles podem ser usados para resolver problemas complexos, tomar decisões, e fazer previsões com base no conhecimento existente.

Arquitetura

A arquitetura dos sistemas baseados em conhecimento é composta de vários componentes que trabalham juntos para representar, adquirir e utilizar o conhecimento para fornecer inteligência aos agentes.

A base dela é a representação do conhecimento. A representação do conhecimento é a forma como o conhecimento é estruturado e armazenado no sistema. Existem várias linguagens e formalismos para tal representação, como ontologias, regras de produção, lógica, entre outros.

O componente seguinte é o mecanismo de inferência. Ele é responsável por inferir novas informações a partir do conhecimento existente. Isso é feito através de regras de inferência, algoritmos de inferência probabilística, entre outros.

O mecanismo de explicação é outro componente importante da arquitetura. Ele é responsável por fornecer explicações sobre as inferências feitas pelo sistema. Isso é útil para entender e avaliar as decisões tomadas pelo sistema.

O mecanismo de adição de conhecimento é responsável por adicionar novo conhecimento ao sistema. Isso pode ser feito manual ou automaticamente, através de processos de aprendizado supervisionado, não supervisionado ou por reforço.

Além disso, os sistemas baseados em conhecimento geralmente incluem mecanismos de gerenciamento de conhecimento, que são responsáveis por garantir a integridade e a consistência do conhecimento armazenado no sistema.

Comparação entre sistemas especialistas e convencionais

Os sistemas especialistas se concentram em resolver problemas específicos em um domínio específico. Eles possuem grande conhecimento especializado em um determinado assunto, como medicina, engenharia, finanças, entre outros.

A principal característica dos sistemas especialistas é a sua capacidade de realizar inferências baseadas em regras de produção, que são conjuntos de regras que descrevem como o conhecimento está relacionado. Essas regras são utilizadas para inferir novas informações a partir do conhecimento existente.

Os sistemas especialistas são compostos de vários componentes, incluindo:

- **Banco de conhecimento:** armazena o conhecimento especializado do sistema.
- **Motor de inferência:** utiliza as regras de produção para inferir novas informações a partir do banco de conhecimento existente.
- **Interface de usuário:** permite ao usuário interagir com o sistema.

Os sistemas convencionais são aqueles que se baseiam em algoritmos e técnicas tradicionais, como redes neurais, algoritmos genéticos, aprendizado de máquina, entre outros. Eles não se concentram em resolver problemas específicos em um domínio específico, como os sistemas especialistas, mas em soluções mais gerais.

Alguns exemplos de técnicas e algoritmos tradicionais utilizados em sistemas convencionais de inteligência artificial incluem:

- **Redes neurais:** que são modelos inspirados na estrutura do cérebro humano e utilizados para resolver problemas de classificação e predição.
- **Algoritmos genéticos:** que são inspirados na evolução biológica e utilizados para resolver problemas de otimização.
- **Aprendizado de máquina:** que é um conjunto de técnicas que permitem que os sistemas aprendam a partir dos dados.

Esses sistemas são amplamente utilizados em várias aplicações, como reconhecimento de fala, visão computacional, processamento de linguagem natural, entre outros. Eles são capazes de solucionar problemas complexos, tomar decisões e fazer previsões com base nos dados fornecidos.

Processo de desenvolvimento de um sistema especialista

O processo de desenvolvimento de um sistema especialista em inteligência artificial envolve várias etapas, incluindo análise do problema, coleta de conhecimento, desenvolvimento do sistema, teste e manutenção.

- A primeira etapa é a análise do problema, em que é identificado o problema específico que o sistema especialista deve resolver e o domínio específico em que ele deve operar.
- Na segunda etapa, coleta-se o conhecimento especializado necessário para o sistema. Isso é feito através de entrevistas com especialistas, estudos de casos, pesquisas em livros e artigos científicos, entre outros.
- Na terceira etapa, o sistema é desenvolvido. Isso inclui a escolha da linguagem de representação do conhecimento, a criação das regras de produção e a implementação do mecanismo de inferência. Além disso, é criada uma interface de usuário para permitir a interação com o sistema.
- Na quarta etapa, o sistema é testado para garantir que ele esteja funcionando corretamente e identificar e corrigir quaisquer problemas.
- A última etapa é a manutenção do sistema, em que são adicionados novos conhecimentos, corrigidos problemas e realizadas atualizações para garantir que o sistema esteja sempre atualizado e funcionando corretamente.

Aplicação

Os sistemas baseados em conhecimento são uma subárea da inteligência artificial (IA) que se concentra na representação, adquirir e utilizar conhecimento para fornecer inteligência. Existem vários exemplos deles que foram desenvolvidos para resolver problemas específicos em diferentes áreas.

Um exemplo é o sistema de assistente financeiro, que utiliza conhecimento financeiro especializado para fornecer conselhos sobre investimentos e planejamento financeiro. Ele é capaz de realizar inferências baseadas em regras de produção e fornece uma lista de possíveis investimentos e estratégias.

Podemos citar como modelos adicionais os sistemas de assistentes virtuais, que utilizam conhecimento em processamento de linguagem natural para entender e responder perguntas de usuários e realizar tarefas. Eles são utilizados em aplicações como assistentes virtuais de atendimento ao cliente, chatbots, entre outros.

Esses são apenas alguns exemplos de sistemas baseados em conhecimento. Há muitos outros que foram desenvolvidos para resolver problemas específicos em diferentes áreas, sendo capazes de fornecer soluções precisas e especializadas para problemas complexos e frequentemente usados como ferramentas de apoio à decisão.



Resumo

Nesta unidade, vimos o significado de pensamento para a inteligência artificial, que se refere à capacidade de uma máquina processar informações, raciocinar e tomar decisões de maneira autônoma, simulando a capacidade humana de pensamento. Isso envolve a utilização de algoritmos, modelos de aprendizado de máquina e redes neurais para analisar dados e extrair insights, além de implementar sistemas de tomada de decisão baseados em regras lógicas e heurísticas. Seu objetivo é criar sistemas que possam aprender, adaptar-se e resolver problemas complexos de forma eficiente, sem a necessidade de intervenção humana constante.

Alguns conceitos importantes foram vistos com agentes lógicos, que são sistemas computacionais que utilizam a lógica como base para a tomada de decisões e resolução de problemas. Eles são compostos de um conjunto de regras e conhecimentos usados para representar e processar informações sobre um determinado domínio. A lógica de primeira ordem é uma extensão da lógica proposicional que permite a representação de objetos e relações entre eles em um domínio específico. Ela é usada para descrever as propriedades e comportamentos dos objetos em um ambiente, além de expressar regras e inferências mais complexas. A inferência de primeira ordem é o processo de dedução lógica que emprega a lógica de primeira ordem para chegar a uma conclusão ou solução a partir de um conjunto de premissas. Isso envolve a aplicação de regras e princípios lógicos para derivar novas informações a partir das informações já conhecidas. Trata-se de uma técnica importante para a resolução de problemas em sistemas inteligentes e agentes lógicos.

Também observamos que conhecimento é o conjunto de informações, experiências, habilidades e compreensão que uma pessoa ou sistema possui sobre um determinado assunto. Sua aquisição se refere ao processo de obter novas informações e habilidades, por meio de experiência ou estudo. A representação do conhecimento é a maneira como ele é estruturado e organizado para que possa ser processado e utilizado por sistemas inteligentes e agentes lógicos. Isso envolve a definição de conceitos, relações e propriedades que são relevantes para o domínio de aplicação.

O raciocínio é o processo pelo qual os sistemas inteligentes e agentes lógicos usam o conhecimento representado para chegar a conclusões e tomar decisões. Isso envolve a aplicação de regras lógicas e heurísticas a fim de processar informações e derivar novos conhecimentos. As linguagens e técnicas para aquisição de conhecimento se referem aos métodos e

ferramentas utilizados para coletar e organizar informações relevantes a um determinado domínio. Isso pode incluir técnicas de mineração de dados, aprendizado de máquina, entrevistas e questionários.

Os sistemas baseados em conhecimento são sistemas computacionais que empregam representações de conhecimento e técnicas de raciocínio para resolver problemas e tomar decisões. Eles são frequentemente usados em aplicações de inteligência artificial, como diagnósticos médicos, planejamento de produção e sistemas especialistas em diversas áreas de conhecimento.



Exercícios

Questão 1. (Enade 2021, adaptada) A lógica proposicional é uma linguagem formal utilizada na inteligência artificial para representar o conhecimento e raciocinar sobre o mundo. As proposições, ou seja, sentenças declarativas classificadas como verdadeiras ou falsas, são representadas por símbolos (geralmente, letras minúsculas do alfabeto). Elas podem ser combinadas por meio de operadores lógicos, de forma a compor sentenças compostas.

Considere que um agente de inteligência artificial está navegando em labirinto e, por meio de seus sensores, represente as proposições a seguir, todas elas verdadeiras.

p: Há uma armadilha na célula (2, 3).

q: Há uma armadilha na célula (3, 4).

r: A célula (3, 3) está vazia.

Considerando os operadores lógicos de negação (não), conjunção (e), disjunção (ou), avalie as afirmativas.

I – Há armadilhas nas células (2, 3) e (3, 3).

II – Há uma armadilha na célula (2, 3) ou a célula (3, 4) está vazia.

III – A célula (3, 3) não está vazia.

É verdadeiro o que se afirma em:

A) I, apenas.

B) II, apenas.

C) I e III, apenas.

D) II e III, apenas.

E) I, II e III.

Resposta correta: alternativa B.

Análise das afirmativas

I – Afirmativa falsa.

Justificativa: a operação de conjunção, que usa o operador "e", exige que ambos os componentes sejam verdadeiros para que a sentença composta seja verdadeira. Há armadilha na célula (2, 3). No entanto, a célula (3, 3) está vazia. Como uma das informações transmitidas é falsa, a proposição composta da afirmativa I é falsa.

II – Afirmativa verdadeira.

Justificativa: a operação de disjunção, que usa o operador "ou", exige que pelo menos um dos componentes seja verdadeiro para que a sentença composta seja verdadeira. Como é verdade que há armadilha na célula (2, 3), isso já é o bastante para que a proposição composta da afirmativa II seja verdadeira.

III – Afirmativa falsa.

Justificativa: a operação de negação, que usa o operador "não", inverte o valor lógico da proposição da qual partiu. Como é verdade que a célula (3, 3) está vazia, é falso que a célula (3, 3) não está vazia. Logo, a proposição da afirmativa III é falsa.

Questão 2. (CESGRANRIO 2018, adaptada) Sistemas especialistas ocupam lugar privilegiado na área de inteligência artificial, mesmo com o avanço de outras áreas. Eles capturam conhecimento tácito de especialistas e podem ser utilizados em processos complexos de tomada de decisão como, por exemplo, diagnósticos médicos. Nesse contexto, assinale a alternativa que NÃO representa uma característica dos sistemas especialistas.

- A) Lidar com incerteza.
- B) Manipular informações simbólicas.
- C) Avaliar relacionamentos complexos.
- D) Contemplar hipóteses múltiplas e simultâneas.
- E) Operar em domínios abrangentes do conhecimento.

Resposta correta: alternativa E.

