



UNIDADE II

Inteligência Artificial

Profa. Dra. Vanessa Lessa

Pensamento

- O pensamento em inteligência artificial se refere à capacidade dos sistemas de IA de processar e manipular informações para solucionar problemas, aprender e tomar decisões. Em outras palavras, o pensamento em IA se refere à capacidade das máquinas de raciocinar e agir de forma semelhante aos seres humanos.
- O pensamento em IA é um campo em constante evolução e é uma área de pesquisa e desenvolvimento ativa na inteligência artificial. À medida que a tecnologia avança, espera-se que as máquinas sejam capazes de realizar tarefas cada vez mais complexas e se aproximarem cada vez mais do pensamento humano.

Agentes lógicos

- Agentes lógicos são programas de computador que utilizam o raciocínio lógico para tomar decisões e realizar ações em um ambiente. Eles usam representações simbólicas para representar conhecimento e inferir conclusões a partir dele.
- Agentes lógicos são uma das principais abordagens utilizadas na inteligência artificial para representar e raciocinar sobre o conhecimento. Eles são compostos por uma série de componentes, como sensores, atuadores, um modelo de ambiente, uma base de conhecimento e um mecanismo de inferência.
 - Os agentes lógicos são capazes de raciocinar de forma dedutiva, indutiva e abdutiva, permitindo que eles tomem decisões com base em diferentes tipos de evidências. Eles também podem ser treinados para aprender com exemplos e melhorar seu desempenho ao longo do tempo.
















Agentes baseados em conhecimento

- Agentes baseados em conhecimento são programas de computador que utilizam representações simbólicas para representar conhecimento e inferir conclusões a partir dele. Eles são um tipo de agente inteligente que utiliza uma base de conhecimento explícita para resolver problemas em um ambiente.
- Esses agentes são capazes de representar o conhecimento de um especialista em uma área específica e usá-lo para realizar tarefas, tomar decisões e realizar ações. Eles são projetados para simular o processo de raciocínio humano, permitindo que os usuários interajam com eles de maneira mais natural.
 - Os agentes baseados em conhecimento geralmente incluem uma base de conhecimento, um mecanismo de inferência e um conjunto de regras ou heurísticas para guiar o processo de tomada de decisão. Eles também podem ser treinados para aprender com exemplos e melhorar seu desempenho ao longo do tempo.


Mundo de Wumpus

- O Mundo de Wumpus é um problema clássico da inteligência artificial que é frequentemente usado para testar algoritmos de raciocínio baseados em lógica. O problema foi proposto por Stuart Russell e Peter Norvig em seu livro *Artificial intelligence: a modern approach* e consiste em um agente que deve navegar em um labirinto para encontrar um tesouro, evitando um monstro chamado Wumpus.
- O mundo de Wumpus é representado por uma grade de células, cada uma contendo um ou mais elementos, como poços, paredes, Wumpus e o tesouro. O agente usa seus sensores para obter informações sobre o ambiente e inferir a localização do tesouro e do Wumpus.
 - O agente pode se mover de uma célula para outra e realizar ações, como atirar uma flecha para matar o Wumpus ou pegar o tesouro. O agente deve ser cuidadoso, pois pode cair em um poço ou ser atacado pelo Wumpus se não for precavido.
 - O problema do mundo de Wumpus é um exemplo clássico de um problema de busca em inteligência artificial, onde o objetivo é encontrar uma solução que leve o agente ao tesouro.


Mundo de Wumpus


4				
3		  		
2				
1	 INICIO			
	1	2	3	4

Fonte: NORVIG (2013, p. 201).

1,4	2,4	3,4	4,4
1,3	2,3	3,3	4,3
1,2	2,2	3,2	4,2
OK			
1,1  OK	2,1 OK	3,1	4,1

(a)


 = Agente
B = Brisa
R = Brilho, Ouro
OK = Quadrado seguro
P = Poço
F = Fedor
V = Visitado
W = Wumpus


1,4	2,4	3,4	4,4
1,3	2,3	3,3	4,3
1,2	2,2 p?	3,2	4,2
OK			
1,1 V OK	2,1  B OK	3,1 p?	4,1

(b)

1,4	2,4	3,4	4,4
1,3 _{w!}	2,3	3,3	4,3
1,2 S OK	2,2 OK	3,2	4,2
1,1 V OK	2,1 B V OK	3,1 p!	4,1

(a)

 = Agente
B = Brisa
R = Brilho, Ouro
OK = Quadrado seguro
P = Poço
F = Fedor
V = Visitado
W = Wumpus

1,4	2,4 p?	3,4	4,4
1,3 _{w!}	2,3  S G B	3,3 p?	4,3
1,2 S V OK	2,2 V OK	3,2	4,2
1,1 V OK	2,1 B V OK	3,1 p!	4,1

(b)

Fonte: NORVIG (2013, p. 202).

Lógica


- Lógica na inteligência artificial é uma ferramenta fundamental para representar o conhecimento e raciocinar sobre o mundo. A lógica é uma disciplina que se preocupa com as regras do raciocínio válido e pode ser aplicada na inteligência artificial de várias maneiras.
- Em IA, a lógica é frequentemente usada para representar o conhecimento de um domínio, como as propriedades de objetos, as relações entre objetos e as ações que podem ser realizadas em um ambiente. A representação do conhecimento em lógica permite que um agente de IA possa inferir novos fatos a partir de fatos já conhecidos e tomar decisões com base nesse conhecimento.

Lógica

- Existem várias linguagens formais de lógica que são usadas em inteligência artificial, como a lógica proposicional, a lógica de predicados e a lógica modal. Cada uma dessas linguagens tem diferentes graus de expressividade e complexidade, permitindo que os agentes de IA representem diferentes tipos de conhecimento.
- Além de ser usada para representar o conhecimento, a lógica também é usada para construir algoritmos de raciocínio em inteligência artificial, como a resolução de problemas e a tomada de decisão. Esses algoritmos usam a lógica para inferir novas informações a partir de fatos conhecidos e tomar decisões com base nesse conhecimento.

Lógica

- Podemos utilizar a lógica e podemos criar os modelos possíveis para representar o mundo Wumpus.
- Modelos possíveis para representar a presença de poços nos quadrados [1,2], [2,2] e [3,1]. BC corresponde às observações de nada em [1,1] e brisa em [2,1] mostrada pela linha sólida. Em (a), as linhas pontilhadas mostram modelos de α_1 (nenhum poço em [1,2]). Em (b), as linhas pontilhadas mostram modelos de α_2 (nenhum poço em [2,2]).



Lógica proposicional

- A lógica proposicional é uma linguagem formal utilizada na inteligência artificial para representar o conhecimento e raciocinar sobre o mundo. Ela é um ramo da lógica matemática que lida com proposições, ou seja, declarações que podem ser verdadeiras ou falsas.
- Na lógica proposicional, as proposições são representadas por símbolos, como p , q , r e assim por diante, e são combinadas usando operadores lógicos, como negação (\neg), conjunção (\wedge), disjunção (\vee), implicação (\rightarrow) e equivalência (\leftrightarrow).

<i>Sentença \rightarrow Sentença Atômica Sentença Complexa</i> <i>Sentença Atômica \rightarrow Verdadeira Falso P Q R ...</i> <i>Sentença Complexa \rightarrow (Sentença) [Sentença]</i> <i> \neg Sentença</i> <i> (Sentença \wedge Sentença)</i> <i> (Sentença \vee Sentença)</i> <i> (Sentença \Rightarrow Sentença)</i> <i> (Sentença \Leftrightarrow Sentença)</i>						
PRECEDÊNCIA DE OPERADORES: \neg , \wedge , \vee , \Rightarrow , \Leftrightarrow						
<i>P</i>	<i>Q</i>	<i>$\neg P$</i>	<i>$P \wedge Q$</i>	<i>$P \vee Q$</i>	<i>$P \Rightarrow Q$</i>	<i>$P \Leftrightarrow Q$</i>
<i>falso</i>	<i>falso</i>	<i>verdadeiro</i>	<i>falso</i>	<i>falso</i>	<i>verdadeiro</i>	<i>verdadeiro</i>
<i>falso</i>	<i>verdadeiro</i>	<i>verdadeiro</i>	<i>falso</i>	<i>verdadeiro</i>	<i>verdadeiro</i>	<i>falso</i>
<i>verdadeiro</i>	<i>falso</i>	<i>falso</i>	<i>falso</i>	<i>verdadeiro</i>	<i>falso</i>	<i>falso</i>
<i>verdadeiro</i>	<i>verdadeiro</i>	<i>falso</i>	<i>verdadeiro</i>	<i>verdadeiro</i>	<i>verdadeiro</i>	<i>verdadeiro</i>

Lógica proposicional

Por exemplo, suponha que um agente de IA está navegando em um labirinto e quer representar a informação de que existem poços em determinadas células. Ele pode usar a lógica proposicional para representar essa informação da seguinte maneira:

- p_1 : Existe um poço na célula (1,1).
- p_2 : Existe um poço na célula (2,3).
- p_3 : Existe um poço na célula (3,2).

Agora, o agente pode usar operadores lógicos para combinar essas proposições e inferir novas informações. Por exemplo, ele pode usar o operador " \neg " (negação) para representar a informação de que uma célula não contém um poço:

- $\neg p_4$: Não há poço na célula (1,2).
- O agente também pode usar o operador " \wedge " (conjunção) para combinar proposições e representar informações mais complexas, como:
 - p_5 : Existem poços nas células (1,1) e (2,3).
 - p_6 : Existe um poço na célula (1,1) e não há poço na célula (1,2).

Prova de teoremas proposicionais

- A prova de teoremas proposicionais é uma técnica usada na inteligência artificial para determinar se uma afirmação é verdadeira ou falsa, com base em um conjunto de axiomas e regras de inferência. Essa técnica é usada principalmente em sistemas de lógica proposicional e é útil para verificar a consistência do conhecimento representado nesses sistemas.
- Uma prova de teoremas proposicionais começa com um conjunto de axiomas, que são proposições consideradas verdadeiras sem a necessidade de prová-las. A partir desses axiomas, o sistema aplica regras de inferência para derivar novas proposições, até chegar à proposição que se deseja provar.
 - A prova de teoremas proposicionais é importante porque permite que os agentes verifiquem se o conhecimento representado em um sistema de lógica proposicional é consistente e livre de contradições. Além disso, a prova de teoremas proposicionais pode ser usada para inferir novas proposições com base em um conjunto de axiomas e regras de inferência, permitindo que os agentes gerem novo conhecimento a partir do conhecimento existente.

Agentes baseados em lógica proposicional

- Agentes baseados em lógica proposicional são agentes de inteligência artificial que utilizam a lógica proposicional para representar seu conhecimento e raciocinar sobre ele.
- Agentes baseados em lógica proposicional geralmente têm um conjunto de proposições que representam seu estado atual, e usam regras de inferência baseadas em lógica proposicional para derivar novas proposições a partir das já existentes. Essas regras de inferência podem ser usadas para modelar o comportamento de um agente, permitindo que ele tome decisões e aja de forma autônoma em um ambiente.
- Os agentes baseados em lógica proposicional são úteis em uma variedade de aplicações em que a lógica proposicional é uma forma natural de representação do conhecimento e podem ajudar a resolver problemas complexos de maneira eficiente e eficaz. Exemplos:
 - Agente de diagnóstico médico;
 - Agente de planejamento;
 - Agente de segurança;
 - Agente de jogos.

Interatividade

Analise as afirmações:

- I. Agentes lógicos usam raciocínio lógico para tomar decisões e realizar ações no ambiente.
- II. Agentes baseados em conhecimento usam representações simbólicas para representar conhecimento e inferir conclusões a partir dele.
- III. Lógica na inteligência artificial é uma ferramenta fundamental para representar o conhecimento e raciocinar sobre o mundo.
- IV. A única linguagem formal usada em inteligência artificial é a lógica proposicional.
- V. A lógica proposicional é uma linguagem formal utilizada na inteligência artificial para representar o conhecimento e raciocinar sobre o mundo.

Está correto o que se afirma em:

- a) I, II e III, apenas.
- b) III e IV, apenas.
- c) I, II, III e V, apenas.
- d) III e IV, apenas.
- e) Todas as afirmações.

Resposta

Analise as afirmações:

- I. Agentes lógicos usam raciocínio lógico para tomar decisões e realizar ações no ambiente.
- II. Agentes baseados em conhecimento usam representações simbólicas para representar conhecimento e inferir conclusões a partir dele.
- III. Lógica na inteligência artificial é uma ferramenta fundamental para representar o conhecimento e raciocinar sobre o mundo.
- IV. A única linguagem formal usada em inteligência artificial é a lógica proposicional.
- V. A lógica proposicional é uma linguagem formal utilizada na inteligência artificial para representar o conhecimento e raciocinar sobre o mundo.

Está correto o que se afirma em:

- a) I, II e III, apenas.
- b) III e IV, apenas.
- c) I, II, III e V, apenas.
- d) III e IV, apenas.
- e) Todas as afirmações.

Lógica de Primeira Ordem

- A Lógica de Primeira Ordem (LPO) é uma extensão da Lógica Proposicional que permite representar e raciocinar sobre quantificadores e variáveis. Na LPO, é possível quantificar sobre objetos e expressar propriedades que são compartilhadas por diferentes objetos.
- A LPO é usada na inteligência artificial para representar conhecimento mais complexo do que a Lógica Proposicional permite. Por exemplo, na LPO é possível representar afirmações como "Todos os gatos são animais" e "Existe um cachorro que late". Isso permite que os agentes de inteligência artificial representem e manipulem conhecimentos mais sofisticados sobre o mundo.
 - A LPO também é usada em tarefas como o raciocínio dedutivo e a inferência automatizada. Por exemplo, um agente de diagnóstico médico pode usar a LPO para representar afirmações sobre sintomas, doenças e tratamentos, e usar inferência automatizada para chegar a um diagnóstico.

Representação

- A Lógica de Primeira Ordem (LPO) é representada em inteligência artificial através de uma linguagem formal que permite expressar proposições complexas usando símbolos e regras gramaticais. Essa linguagem é chamada de linguagem de primeira ordem ou lógica de predicados.
- A linguagem de primeira ordem consiste em símbolos para constantes, funções, predicados e variáveis. Constantes representam objetos específicos, como números ou nomes próprios. Funções representam mapeamentos de objetos em outros objetos. Predicados representam propriedades ou relações que podem ser aplicadas a objetos. Variáveis são usadas para representar objetos não especificados.
 - Por exemplo, suponha que queremos representar a proposição "Todos os gatos são animais". Podemos fazer isso usando a linguagem de primeira ordem, com um símbolo de predicado "gato(x)" que representa a propriedade de ser um gato e um símbolo de predicado "animal(x)" que representa a propriedade de ser um animal. A proposição pode ser escrita como "para todo x, se gato(x), então animal(x)".

Sintaxe e semântica da lógica de primeira ordem

- A sintaxe da lógica de primeira ordem (LPO) é baseada em termos, fórmulas bem formadas e quantificadores. Os termos podem ser constantes, variáveis e funções. As fórmulas bem formadas podem ser átomos, fórmulas moleculares, ou fórmulas complexas com operadores lógicos, quantificadores e conectivos. Os quantificadores "para todo" e "existe" permitem generalizar sobre variáveis livres, o que significa que eles ligam variáveis às fórmulas e permitem afirmar algo sobre todos os objetos de um determinado domínio.
- A semântica da LPO é dada por meio da interpretação de termos, predicados e quantificadores em um determinado domínio de discurso. Cada interpretação atribui significado a cada símbolo em um domínio de discurso, e a partir disso, atribui um valor verdade para cada fórmula da LPO. As interpretações também permitem definir modelos, que são estruturas matemáticas que representam o domínio de discurso e que descrevem como as fórmulas são verdadeiras ou falsas nesse domínio. Por exemplo:
 - "para todo x , se x é um número inteiro positivo, então x é maior que zero".

Utilização da lógica de primeira ordem

- A utilização da LPO na IA envolve a definição de um conjunto de axiomas e regras que descrevem o domínio de discurso em questão. Esses axiomas e regras são escritos em uma linguagem formal, como a LPO, e podem ser usados por um motor de inferência para deduzir novas informações a partir das informações existentes. O motor de inferência é um componente central de muitos sistemas de IA, pois é responsável por aplicar as regras e axiomas para obter conclusões a partir de fatos conhecidos.
- A LPO é usada em muitas áreas da IA, como em sistemas de recomendação, onde a LPO pode ser usada para representar o perfil de um usuário, os itens recomendados e as relações entre eles. Com essa representação formal, o motor de inferência pode gerar recomendações personalizadas com base no conhecimento representado.
 - Outra aplicação é na modelagem de sistemas complexos, como sistemas de controle de tráfego aéreo. A LPO pode ser usada para representar as restrições e regras de segurança que devem ser seguidas pelos aviões e controladores de tráfego aéreo. Com essa representação formal, o motor de inferência pode ajudar os controladores a tomar decisões seguras e eficientes em tempo real.

Engenharia de conhecimento em lógica de primeira ordem

- É uma abordagem para o desenvolvimento de sistemas especialistas e outros sistemas de IA que se baseiam em conhecimento formalizado e regras de inferência.
- O processo de engenharia de conhecimento em LPO começa com a identificação e análise do domínio do problema em questão. Isso envolve a identificação dos conceitos relevantes, relações e funções que descrevem o domínio, bem como as regras e restrições que governam o comportamento dos elementos do domínio.
- Com base na análise do domínio, os engenheiros de conhecimento desenvolvem uma ontologia que descreve os conceitos e relações relevantes do domínio em termos de axiomas formais da LPO. Essa ontologia é a base para o sistema de IA, e é usada para representar o conhecimento necessário para resolver problemas no domínio.
 - Os engenheiros de conhecimento desenvolvem uma base de regras que descreve como o conhecimento na ontologia pode ser combinado e inferido para produzir novas informações. Essas regras de inferência podem ser escritas em LPO e usadas por um motor de inferência para deduzir novas informações a partir das informações existentes.

Inferência em Lógica de Primeira Ordem

- Inferência em lógica de primeira ordem é o processo de deduzir conclusões a partir de um conjunto de premissas na forma de cláusulas. Esse processo é executado por meio da aplicação de regras de inferência, que determinam como as cláusulas podem ser combinadas e manipuladas para gerar novas cláusulas ou inferências.
- O objetivo da inferência em lógica de primeira ordem na inteligência artificial é automatizar o processo de raciocínio e tomada de decisão em sistemas de conhecimento baseados em LPO. Isso é feito por meio de mecanismos de inferência que podem ser incorporados em sistemas especialistas, agentes inteligentes, sistemas de recomendação e outros aplicativos de IA que envolvem raciocínio sobre informações complexas.
 - A inferência em LPO é uma área de pesquisa ativa na inteligência artificial e continua a evoluir com a descoberta de novos métodos e técnicas. A inferência em LPO é fundamental para a construção de sistemas inteligentes que podem raciocinar e tomar decisões com base em informações complexas e heterogêneas.

Inferência proposicional versus inferência de primeira ordem

- A inferência proposicional e a inferência de primeira ordem são duas técnicas fundamentais de raciocínio em lógica matemática e inteligência artificial. A seguir, serão apresentadas algumas diferenças entre esses dois tipos de inferência:
- Escopo de expressividade: A lógica proposicional é limitada à expressão de proposições simples e relacionamentos entre elas, enquanto a lógica de primeira ordem permite a expressão de proposições complexas envolvendo quantificação e relacionamentos entre objetos e predicados.

Inferência proposicional versus inferência de primeira ordem

- Flexibilidade semântica: A lógica proposicional é inflexível em relação às possíveis interpretações semânticas, enquanto a lógica de primeira ordem é capaz de lidar com diferentes interpretações semânticas, permitindo o uso de variáveis quantificadas e fórmulas abertas.
- Eficiência computacional: A inferência proposicional é computacionalmente mais eficiente do que a inferência de primeira ordem, já que requer menos operações de processamento de dados. Por outro lado, a inferência de primeira ordem é mais expressiva e flexível, permitindo lidar com problemas mais complexos.
 - Reusabilidade de conhecimento: A lógica proposicional é mais fácil de aplicar em diferentes domínios de conhecimento, mas é menos reutilizável do que a lógica de primeira ordem. A lógica de primeira ordem permite a construção de ontologias e sistemas de conhecimento mais abrangentes e reutilizáveis em diferentes domínios.

Unificação e inferência de primeira ordem

- Unificação é uma técnica utilizada na lógica de primeira ordem para encontrar substituições que tornem duas fórmulas logicamente equivalentes. A unificação é um passo fundamental em muitos algoritmos de inferência automatizada.
- O processo de inferência de primeira ordem começa com um conjunto de fórmulas conhecidas, que são chamadas de premissas. A inferência de primeira ordem usa regras de inferência para derivar novas fórmulas a partir dessas premissas. Essas novas fórmulas são então adicionadas ao conjunto de premissas, e o processo é repetido até que não seja possível inferir novas fórmulas.
 - A unificação é uma técnica importante para a inferência de primeira ordem, porque permite encontrar substituições que tornam duas fórmulas equivalentes. Por exemplo, se tivermos as fórmulas " $P(x)$ " e " $P(a)$ ", podemos unificá-las, substituindo " x " por " a ", para obter a fórmula " $P(a)$ ". A unificação é usada para unificar fórmulas durante a aplicação de regras de inferência, como a resolução de predicados e a eliminação de quantificadores.

Encadeamento para frente

- O encadeamento para frente, também conhecido como encadeamento direto ou encadeamento progressivo, é um método de inferência utilizado em sistemas baseados em conhecimento da inteligência artificial. Ele começa com um conjunto de fatos conhecidos e regras, e tenta deduzir novos fatos ou conclusões a partir deles. O encadeamento para frente trabalha iterativamente a partir dos fatos conhecidos e aplica as regras para gerar novas informações, até que uma resposta seja encontrada ou até que não haja mais regras a serem aplicadas.
- Um exemplo simples de encadeamento para frente é o seguinte:
 - Suponha que temos um sistema de diagnóstico médico que usa uma base de conhecimento para determinar a doença de um paciente. A base de conhecimento contém fatos sobre os sintomas que o paciente apresenta e regras que relacionam esses sintomas a doenças. O encadeamento para frente começaria com os sintomas conhecidos do paciente e aplicaria as regras apropriadas para deduzir a doença que o paciente tem.

Encadeamento para trás

- O encadeamento para trás é um método de inferência utilizado em sistemas baseados em conhecimento da inteligência artificial. Ao contrário do encadeamento para frente, que começa com fatos conhecidos e regras e tenta deduzir novas informações a partir deles, o encadeamento para trás começa com a hipótese que se deseja provar e trabalha "para trás" para encontrar fatos e regras que possam levar à conclusão desejada.
- O encadeamento para trás é particularmente útil em sistemas de diagnóstico e planejamento, nos quais o objetivo é determinar quais ações devem ser tomadas para atingir uma meta específica.
 - Por exemplo, se o objetivo é fazer um bolo, o encadeamento para trás poderia começar com a hipótese de que o bolo precisa ser assado e, em seguida, trabalhar "para trás" para determinar quais ingredientes e utensílios são necessários, bem como quais etapas precisam ser seguidas para preparar e assar o bolo.

Resolução

- Resolução é uma técnica de inferência em lógica de primeira ordem usada para inferir novas cláusulas a partir de um conjunto de cláusulas existentes. A técnica envolve a unificação de duas cláusulas para produzir uma nova cláusula.
- É particularmente útil em tarefas que envolvem a prova de teoremas e verificação formal de sistemas, onde é necessário determinar se um conjunto de axiomas ou regras pode ser usado para inferir uma determinada conclusão.
 - A técnica de resolução pode ser aplicada em vários tipos de lógica de primeira ordem, incluindo a lógica proposicional. A resolução é geralmente usada em combinação com outras técnicas de inferência, como o encadeamento para trás, para permitir que os sistemas de IA determinem se uma conclusão pode ser inferida a partir de um conjunto de premissas ou fatos dados.

Interatividade

Analise as afirmações:

- I. A Lógica de Primeira Ordem (LPO) é uma extensão da Lógica Proposicional que permite representar e raciocinar sobre quantificadores e variáveis.
- II. A sintaxe da LPO é baseada em termos, fórmulas bem formadas e quantificadores.
- III. A semântica da LPO é dada por meio da interpretação de termos, predicados e quantificadores em um determinado domínio de discurso.
- IV. O motor de inferência é um componente central de muitos sistemas de IA, é responsável por aplicar as regras e axiomas para obter conclusões a partir de fatos conhecidos.
- V. O processo de engenharia de conhecimento em LPO começa com a identificação e análise do domínio do problema em questão.

Está correto o que se afirma em:

- a) I, II e III, apenas.
- b) I, II e IV, apenas.
- c) I, II e V, apenas.
- d) I, III, IV e V, apenas.
- e) Todas as afirmações.

Resposta

Analise as afirmações:

- I. A Lógica de Primeira Ordem (LPO) é uma extensão da Lógica Proposicional que permite representar e raciocinar sobre quantificadores e variáveis.
- II. A sintaxe da LPO é baseada em termos, fórmulas bem formadas e quantificadores.
- III. A semântica da LPO é dada por meio da interpretação de termos, predicados e quantificadores em um determinado domínio de discurso.
- IV. O motor de inferência é um componente central de muitos sistemas de IA, é responsável por aplicar as regras e axiomas para obter conclusões a partir de fatos conhecidos.
- V. O processo de engenharia de conhecimento em LPO começa com a identificação e análise do domínio do problema em questão.

Está correto o que se afirma em:

- a) I, II e III, apenas.
- b) I, II e IV, apenas.
- c) I, II e V, apenas.
- d) I, III, IV e V, apenas.
- e) Todas as afirmações.

Representação do conhecimento

- O conhecimento é um aspecto fundamental da inteligência artificial (IA) e é usado em várias tarefas, como reconhecimento de padrões, aprendizado de máquina, planejamento, diagnóstico, entre outras. O conhecimento pode ser adquirido de fontes externas, como bases de dados ou especialistas humanos, ou pode ser aprendido através da interação com o ambiente.
- Um sistema de reconhecimento de padrões pode ser composto pelas seguintes etapas: aquisição de dados; pré-processamento, para eliminar ruídos ou distorções dos dados adquiridos; extração de características (ou atributos), onde criamos um vetor de características com dados extraídos dos objetos adquiridos, reduzindo os dados a atributos, propriedades ou características; triagem de características, que analisa o conjunto de características e exclui as mais redundantes; e classificador, que toma uma certa decisão baseando-se na análise de um padrão (Duda; Hart; Stork, 2000).
 - O classificador analisa um conjunto de treinamento com exemplos de todas as classes existentes no sistema, e toma decisões baseando-se no aprendizado dessa análise.

Aquisição do Conhecimento

- Aquisição de Conhecimento é o processo de adquirir, representar e organizar informações para que possam ser usadas pelos sistemas de inteligência artificial. Isso inclui tanto a coleta de dados quanto a sua interpretação e organização.

Existem vários métodos utilizados para a aquisição de conhecimento em inteligência artificial. Alguns dos principais incluem:

1. **Aprendizado automático:** é um processo de adquirir conhecimento a partir de dados utilizando algoritmos de aprendizado de máquina.
2. **Inferência lógica:** é um processo de adquirir conhecimento a partir de inferências baseadas em regras lógicas.

Métodos de Aquisição do Conhecimento

3. Raspagem de dados: é o processo de coletar dados de fontes na internet, como sites, redes sociais, e bancos de dados.
4. Adquirir conhecimento de fontes humanas, como especialistas, livros, artigos científicos, entrevistas, etc.
5. Aprendizado de reforço: é um processo de aquisição de conhecimento através de tentativa e erro, onde o sistema aprende a partir de suas ações e suas consequências.
6. Aprendizado por demonstração: é um processo de aquisição de conhecimento através de exemplos, onde o sistema aprende a partir da observação de ações humanas.
 7. Aprendizado por observação: é um processo de aquisição de conhecimento através da observação de um ambiente sem intervenção direta.
 8. Aprendizado por exploração: é um processo de aquisição de conhecimento através da exploração ativa do ambiente.

Entrevistas não estruturadas

- Entrevistas não estruturadas são uma técnica de coleta de dados utilizada para adquirir conhecimento de fontes humanas. Elas são chamadas de "não estruturadas" porque não seguem um roteiro fixo de perguntas, permitindo que o entrevistado responda livremente e forneça informações adicionais que podem não ter sido previstas. Entrevistas não estruturadas são usadas para coletar informações qualitativas, como opiniões, crenças, motivações e percepções. Elas são geralmente realizadas por meio de conversas informais e são conduzidas por pesquisadores ou entrevistadores com habilidades específicas. Elas são frequentemente usadas em campos como psicologia, sociologia, antropologia e estudos de mercado.

Entrevistas estruturadas

- Entrevistas estruturadas são uma técnica de coleta de dados que segue um roteiro fixo de perguntas. Essas perguntas são previamente planejadas e testadas, e são feitas para todos os participantes da entrevista. Elas são úteis para coletar dados quantitativos e comparáveis, pois as perguntas são formuladas de forma a serem respondidas de forma objetiva. As entrevistas estruturadas podem ser realizadas por meio de questionários escritos ou entrevistas face a face. Elas são frequentemente usadas em campos como estatística, ciências sociais e psicologia. Entrevistas estruturadas também são mais objetivas e menos suscetíveis a viés de interpretação do que as entrevistas não estruturadas.

Estudo de caso

- Um estudo de caso em inteligência artificial é uma técnica utilizada para investigar e compreender um sistema ou problema específico. Ele geralmente envolve a coleta de dados a partir de uma variedade de fontes, como entrevistas, registros, observações, e análise de documentos. O objetivo é fornecer uma descrição detalhada e abrangente do sistema ou problema em questão. Estudos de caso são comumente usados para avaliar a eficácia de sistemas de inteligência artificial, identificar problemas e melhorias, e fornecem exemplos de como a tecnologia pode ser aplicada em um contexto específico. Eles também são usados para desenvolver e testar hipóteses, identificar tendências e padrões, e propor soluções para problemas específicos.

Descoberta de Conhecimento em Base de Dados (KDD)

- Descoberta de Conhecimento em Base de Dados (KDD, do inglês *Knowledge Discovery in Databases*) é o processo de identificar padrões e relações significativas em grandes conjuntos de dados. É uma abordagem interdisciplinar que combina técnicas de estatística, aprendizado de máquina, mineração de dados e banco de dados para extrair informações úteis e valiosas a partir de dados brutos. O objetivo é transformar grandes quantidades de dados não estruturados em informações estruturadas e úteis que possam ser usadas para tomar decisões informadas. A KDD é amplamente utilizada em aplicações como *marketing*, finanças, saúde e segurança, e pode ser usada para identificar tendências, prever eventos futuros, e melhorar a eficiência de processos empresariais.

Métodos de representação de conhecimento

Em inteligência artificial, os métodos de representação de conhecimento são técnicas utilizadas para representar e armazenar informações de maneira que possam ser processadas e compreendidas pelos sistemas de inteligência artificial. Alguns dos métodos mais comuns incluem:

1. Representação baseada em regras: é uma representação de conhecimento que se baseia em regras lógicas e condicionais.
2. Representação baseada em *frames*: é uma representação de conhecimento que se baseia em estruturas de dados chamadas "*frames*", que contêm informações sobre um objeto ou conceito.
3. Representação baseada em ontologias: é uma representação de conhecimento que se baseia em ontologias, que são modelos de conceitos e relações que descrevem um domínio específico.

Métodos de representação de conhecimento

4. Representação baseada em redes neurais: é uma representação de conhecimento que se baseia em redes neurais, que são modelos matemáticos inspirados na estrutura do cérebro humano que são capazes de aprender e generalizar a partir de exemplos.
5. Representação baseada em sistemas *fuzzy*: é uma representação de conhecimento que se baseia em lógica *fuzzy*, que permite lidar com incertezas e imprecisões.
6. Representação baseada em lógica probabilística: é uma representação de conhecimento que se baseia em lógica probabilística, que permite lidar com incertezas e imprecisões.

Redes

- Redes são estruturas de dados utilizadas para representar relações e interações entre diferentes elementos. Elas podem ser utilizadas para representar diversos tipos de relações, tais como relações semânticas entre palavras, relações causais entre eventos, relações topológicas entre objetos, entre outras. As redes são frequentemente utilizadas para representar e processar informações complexas de maneira estruturada e eficiente.
- Existem vários tipos de redes, como redes neurais, redes bayesianas, redes markovianas, redes sociais, entre outros.
 - Redes neurais são inspiradas na estrutura do cérebro humano e são usadas para aprender e generalizar a partir de exemplos.
 - Redes bayesianas são usadas para modelar incertezas e probabilidades.
 - Redes markovianas são usadas para modelar processos estocásticos e sistemas dinâmicos.
 - Redes sociais são usadas para modelar e analisar relações entre indivíduos ou entidades em um sistema social.

Redes bayesianas

- Redes bayesianas (também conhecidas como redes de probabilidade ou modelos de Bayes) são modelos gráficos probabilísticos que permitem a representação e o raciocínio sobre a incerteza em sistemas complexos.
- As redes bayesianas são baseadas na teoria de probabilidade bayesiana, que é uma abordagem matemática para quantificar a incerteza por meio da atualização de probabilidades com base em novas informações. Esses modelos são representados por um grafo direcionado acíclico, em que os nós representam as variáveis do sistema e as arestas representam as relações de dependência entre essas variáveis.
 - As redes bayesianas são usadas para modelar sistemas em que as variáveis estão interconectadas de maneira complexa e em que há incerteza em relação ao estado dessas variáveis. Por exemplo, uma rede bayesiana pode ser usada para modelar o risco de doenças em uma população, em que as variáveis podem incluir idade, histórico médico, estilo de vida e outros fatores que influenciam o risco de uma pessoa desenvolver uma determinada doença.

Redes markovianas

- Redes markovianas (também conhecidas como processos de Markov) são modelos estocásticos usados em ciência da computação, matemática, física, biologia, economia e outras áreas para descrever a evolução temporal de sistemas complexos que exibem comportamento aleatório.
- Uma rede markoviana é um modelo matemático que descreve a probabilidade de transição entre estados de um sistema, onde a probabilidade de transição depende apenas do estado atual e não dos estados anteriores. Em outras palavras, a propriedade fundamental de um processo de Markov é a propriedade de Markov, que afirma que o futuro é independente do passado, dado o presente.
 - As redes markovianas são usadas para modelar sistemas em que as transições entre estados são aleatórias, mas seguem certas regras probabilísticas. Por exemplo, uma rede markoviana pode ser usada para modelar a evolução temporal de uma população de animais, em que o número de animais em uma determinada época é influenciado por fatores aleatórios, como a mortalidade e a reprodução, mas esses fatores seguem certas regras probabilísticas.

Frames

- *Frames* em inteligência artificial são uma forma de representação de conhecimento que descrevem objetos, conceitos ou eventos de um determinado domínio. Eles são compostos por atributos e valores que descrevem as características de um objeto ou conceito, e relações entre os objetos ou conceitos.
- São uma forma de representar conhecimento especializado e fornecem uma estrutura para organizar e recuperar informações de maneira eficiente. Eles são comumente usados em sistemas de inteligência artificial que lidam com tarefas de processamento de linguagem natural, reconhecimento de objetos, diagnóstico, entre outras. O uso de *frames* permite modelar o conhecimento de um domínio específico de forma estruturada e fácil de ser acessado e utilizado pelos sistemas de inteligência artificial.

Árvores de decisão

- Árvores de decisão são uma técnica de aprendizado de máquina supervisionado que são utilizadas para classificação e tomada de decisão. Elas são compostas por nós de decisão e nós de folha, onde cada nó de decisão representa uma decisão ou uma característica do problema, e cada nó de folha representa uma classe ou uma decisão final.
- A construção de uma árvore de decisão começa com o nó raiz, que representa a característica mais importante para classificar os dados, e os nós subsequentes são construídos recursivamente, dependendo das características dos dados e das decisões tomadas nos nós anteriores.

Ontologias

- Ontologia é um campo da inteligência artificial que se concentra na representação e organização do conhecimento. Ela envolve a criação de uma estrutura hierárquica de conceitos e relações entre eles, chamada de ontologia. Essa estrutura é utilizada para representar de forma formal e precisa o conhecimento de um determinado domínio ou área. As ontologias são usadas em diversas aplicações, como sistemas de recuperação de informação, inteligência artificial distribuída, robótica, e inteligência artificial baseada em agentes.

Interatividade

Analise as afirmações:

- I. O conhecimento pode ser adquirido apenas nas bases de dados.
- II. No sistema de reconhecimento de padrões, o classificador analisa um conjunto de treinamento com todas as classes existentes no sistema, e decide baseando-se no aprendizado dessa análise.
- III. Aquisição de Conhecimento é o processo de adquirir, representar e organizar informações para que possam ser usadas pelos sistemas de inteligência artificial.
- IV. Entrevistas não estruturadas são uma técnica de coleta de dados utilizada para adquirir conhecimento da base de dados.
- V. Descoberta de Conhecimento em Base de Dados é o processo de identificar padrões e relações significativas em grandes conjuntos de dados.

Está correto o que se afirma em:

- a) I, II e III, apenas.
- b) I, II e IV, apenas.
- c) II, III e V, apenas.
- d) III, IV e V, apenas.
- e) Todas as afirmações.

Resposta

Analise as afirmações:

- I. O conhecimento pode ser adquirido apenas nas bases de dados.
- II. No sistema de reconhecimento de padrões, o classificador analisa um conjunto de treinamento com todas as classes existentes no sistema, e decide baseando-se no aprendizado dessa análise.
- III. Aquisição de Conhecimento é o processo de adquirir, representar e organizar informações para que possam ser usadas pelos sistemas de inteligência artificial.
- IV. Entrevistas não estruturadas são uma técnica de coleta de dados utilizada para adquirir conhecimento da base de dados.
- V. Descoberta de Conhecimento em Base de Dados é o processo de identificar padrões e relações significativas em grandes conjuntos de dados.

Está correto o que se afirma em:

- a) I, II e III, apenas.
- b) I, II e IV, apenas.
- c) II, III e V, apenas.
- d) III, IV e V, apenas.
- e) Todas as afirmações.

Representação do conhecimento e raciocínio.

- A representação do conhecimento é uma tarefa fundamental na inteligência artificial (IA), pois permite que os agentes inteligentes armazenem, acessem e utilizem o conhecimento de forma eficiente. Existem várias formas de representar o conhecimento na IA, cada uma com suas próprias vantagens e desvantagens.
- Uma das formas mais comuns de representação do conhecimento é através de regras de produção. As regras de produção consistem em uma condição e em uma ação, e são usadas para representar relações lógicas entre conceitos. Por exemplo, uma regra de produção pode ser "Se o animal é um cachorro, então ele é um mamífero".

Representação do conhecimento e raciocínio.

- Outra forma comum de representação do conhecimento é através de ontologias, que são modelos de conhecimento que descrevem a estrutura conceitual de um domínio específico. As ontologias são compostas por conceitos, propriedades e relações e são usadas para representar o conhecimento de forma estruturada e consistente.
- Os mapas conceituais são outra forma de representação de conhecimento, que consistem em diagramas que representam relações entre conceitos. Eles são usados para representar o conhecimento de forma visual e intuitiva.
- Os grafos de conhecimento são uma forma de representar conhecimento através de estruturas de dados que representam relações entre entidades. Eles são usados para representar o conhecimento de forma estruturada e flexível.
 - A representação do conhecimento permite que os agentes inteligentes armazenem, acessem e utilizem o conhecimento de forma eficiente. A escolha da representação de conhecimento adequada é crucial para o desempenho e a eficiência dos agentes inteligentes, e deve ser adaptada para cada problema específico.

Representação do conhecimento e raciocínio

- A representação do raciocínio permite que os agentes inteligentes tomem decisões e resolvam problemas de forma eficiente. Existem várias formas de representar o raciocínio na IA, cada uma com suas próprias vantagens e desvantagens.
- Uma forma comum de representação do raciocínio é através de lógica formal, que é uma forma de representar o raciocínio que utiliza símbolos e regras para representar proposições e inferências lógicas. A lógica proposicional e a lógica de primeira ordem são exemplos de lógicas formais que são amplamente utilizadas na IA.
- Outra forma de representação do raciocínio é através de redes neurais, que são modelos computacionais inspirados em como o cérebro humano processa informações, e são usadas para representar e inferir relações entre entrada e saída. As redes neurais são amplamente utilizadas em tarefas de reconhecimento de padrões e aprendizado de máquina.
 - As redes bayesianas são outra forma de representação do raciocínio, que combina probabilidade e lógica para representar relações entre eventos. Elas são usadas para representar o raciocínio probabilístico, no qual são levadas em conta as incertezas e as variações.

Linguagens e técnicas para aquisição

- As linguagens para aquisição de conhecimento são ferramentas utilizadas na inteligência artificial (IA) para representar e adquirir conhecimento de forma estruturada e eficiente. Existem várias linguagens para aquisição de conhecimento, cada uma com suas próprias características e aplicações.
- Uma das linguagens mais comuns para aquisição de conhecimento é a lógica formal. Outra linguagem comum para aquisição de conhecimento é a linguagem de ontologia, que é uma linguagem específica utilizada para representar ontologias, que são modelos de conhecimento que descrevem a estrutura conceitual de um domínio específico. Essa linguagem é amplamente utilizada em tarefas de recuperação de informação e inteligência artificial semântica.
 - A linguagem de descrição de objetos (ODL) é outra linguagem comum para aquisição de conhecimento, essa linguagem é usada para representar o conhecimento de forma estruturada, utilizada em sistemas de recuperação de informação, inteligência artificial, e outras áreas.

Sistemas baseados em conhecimento

- Os sistemas baseados em conhecimento são uma subárea da inteligência artificial (IA) que se concentra na representação, aquisição e utilização do conhecimento para fornecer inteligência aos agentes. Esses sistemas utilizam conhecimento estruturado para representar o conhecimento e inferir novas informações.
- Os sistemas baseados em conhecimento são compostos de vários componentes, incluindo:
 - Mecanismos de inferência: que permitem inferir novas informações a partir do conhecimento existente.
 - Representação do conhecimento: que permite representar o conhecimento de forma estruturada e eficiente.
 - Mecanismos de explicação: que permitem explicar as inferências feitas pelo sistema.
 - Mecanismos de adição de conhecimento: que permitem adicionar novo conhecimento ao sistema.

Arquitetura

- A arquitetura dos sistemas baseados em conhecimento é composta por vários componentes que trabalham juntos para representar, adquirir e utilizar o conhecimento para fornecer inteligência aos agentes.
- A base da arquitetura é a representação do conhecimento. A representação do conhecimento é a forma como o conhecimento é estruturado e armazenado no sistema. Existem várias linguagens e formalismos para representação do conhecimento.
 - O componente seguinte é o mecanismo de inferência. O mecanismo de inferência é responsável por inferir novas informações a partir do conhecimento existente. Isso é feito através de regras de inferência, algoritmos de inferência probabilística, entre outros.

Arquitetura

- O mecanismo de explicação é outro componente importante da arquitetura. Ele é responsável por fornecer explicações sobre as inferências feitas pelo sistema. Isso é útil para entender e avaliar as decisões tomadas pelo sistema.
- O mecanismo de adição de conhecimento é responsável por adicionar novo conhecimento ao sistema. Isso pode ser feito manualmente ou automaticamente, através de processos de aprendizado supervisionado, não supervisionado ou por reforço.
 - Além disso, os sistemas baseados em conhecimento geralmente incluem mecanismos de gerenciamento de conhecimento, que são responsáveis por garantir a integridade e a consistência do conhecimento armazenado no sistema.

Comparação entre sistemas especialistas e convencionais

- Os sistemas especialistas se concentram em resolver problemas específicos em um domínio específico. Esses sistemas possuem um grande conhecimento especializado em um determinado assunto, como medicina, engenharia, finanças, entre outros.
- A principal característica dos sistemas especialistas é a sua capacidade de realizar inferências baseadas em regras de produção, que são conjuntos de regras que descrevem como o conhecimento está relacionado. Essas regras são utilizadas para inferir novas informações a partir do conhecimento existente.

Os sistemas especialistas são compostos de vários componentes, incluindo:

- Banco de conhecimento: que armazena o conhecimento especializado do sistema.
 - Motor de inferência: que utiliza as regras de produção para inferir novas informações a partir do conhecimento existente.
 - Interface de usuário: que permite ao usuário interagir com o sistema.

Comparação entre sistemas especialistas e convencionais

- Os sistemas convencionais são aqueles que se baseiam em algoritmos e técnicas tradicionais, como redes neurais, algoritmos genéticos, aprendizado de máquina, entre outros. Esses sistemas não se concentram em resolver problemas específicos em um domínio específico, como os sistemas especialistas, mas sim em soluções mais gerais.
- Alguns exemplos de técnicas e algoritmos tradicionais utilizados em sistemas convencionais de inteligência artificial incluem:
 - Redes neurais: que são modelos inspirados na estrutura do cérebro humano e são utilizadas para resolver problemas de classificação e predição.
 - Algoritmos genéticos: que são inspirados na evolução biológica e são utilizados para resolver problemas de otimização.
 - Aprendizado de máquina: que é um conjunto de técnicas que permitem que os sistemas aprendam a partir dos dados.

Processo de desenvolvimento de um sistema especialista

- O processo de desenvolvimento de um sistema especialista em inteligência artificial envolve várias etapas, incluindo análise do problema, coleta de conhecimento, desenvolvimento do sistema, teste e manutenção.
- A primeira etapa é a análise do problema, onde é identificado o problema específico que o sistema especialista deve resolver e o domínio específico em que ele deve operar.
- Na segunda etapa, coleta-se o conhecimento especializado necessário para o sistema. Isso é feito através de entrevistas com especialistas, estudos de casos, pesquisas em livros e artigos científicos, entre outros.

Processo de desenvolvimento de um sistema especialista

- Na terceira etapa, o sistema é desenvolvido. Isso inclui a escolha da linguagem de representação do conhecimento, a criação das regras de produção e a implementação do mecanismo de inferência. Além disso, é desenvolvida uma interface de usuário para permitir a interação com o sistema.
- Na quarta etapa, o sistema é testado para garantir que ele esteja funcionando corretamente e para identificar e corrigir quaisquer problemas.
 - A última etapa é a manutenção do sistema, onde é adicionado novo conhecimento, corrigidos problemas e realizadas atualizações para garantir que o sistema esteja sempre atualizado e funcionando corretamente.

Aplicação

- Os sistemas baseados em conhecimento são uma subárea da inteligência artificial (IA) que se concentra na representação, adquirir e utilizar conhecimento para fornecer inteligência. Existem vários exemplos de sistemas baseados em conhecimento que foram desenvolvidos para resolver problemas específicos em diferentes áreas.
- Um exemplo é o sistema de assistente financeiro, que utiliza conhecimento financeiro especializado para fornecer conselhos sobre investimentos e planejamento financeiro. Ele é capaz de realizar inferências baseadas em regras de produção e fornece uma lista de possíveis investimentos e estratégias.
 - Um exemplo adicional é o dos sistemas de assistentes virtuais, que utilizam conhecimento em processamento de linguagem natural para entender e responder perguntas de usuários e realizar tarefas. Eles são utilizados em aplicações como assistentes virtuais de atendimento ao cliente, *chatbots*, entre outros.

Interatividade

Analise as afirmações:

- I. A representação do conhecimento permite que os agentes inteligentes armazenem, acessem e utilizem o conhecimento de forma eficiente.
- II. Mecanismos de inferência permitem inferir novas informações a partir do conhecimento existente.
- III. Representação do conhecimento permite representar o conhecimento de forma estruturada e eficiente.
- IV. Os sistemas especialistas se concentram em resolver problemas em um domínio específico.
- V. Os sistemas convencionais são aqueles que se baseiam em algoritmos e técnicas tradicionais.

Está correto o que se afirma em:

- a) I, II e III, apenas.
- b) I, II e IV, apenas.
- c) I, II e V, apenas.
- d) III, IV e V, apenas.
- e) Todas as afirmações.

Resposta

Analise as afirmações:

- I. A representação do conhecimento permite que os agentes inteligentes armazenem, acessem e utilizem o conhecimento de forma eficiente.
- II. Mecanismos de inferência permitem inferir novas informações a partir do conhecimento existente.
- III. Representação do conhecimento permite representar o conhecimento de forma estruturada e eficiente.
- IV. Os sistemas especialistas se concentram em resolver problemas em um domínio específico.
- V. Os sistemas convencionais são aqueles que se baseiam em algoritmos e técnicas tradicionais.

Está correto o que se afirma em:

- a) I, II e III, apenas.
- b) I, II e IV, apenas.
- c) I, II e V, apenas.
- d) III, IV e V, apenas.
- e) Todas as afirmações.

Referências

- DUDA, R.; HART, P.; STORK, D. Pattern classification. 2. ed. New York: John Wiley Sons Inc., 2000.
- NORVIG, Peter. *Inteligência artificial*. 3. ed. São Paulo: Grupo GEN, 2013.

ATÉ A PRÓXIMA!